

Impacto de la predicción del rendimiento académico en la percepción estudiantil

Sebastián Ignacio Luarte Becar¹

Universidad Austral de Chile, Valdivia, Chile
sebastian.luarte@alumnos.uach.cl

Resumen En los últimos años, la predicción del abandono y rendimiento académico ha cobrado interés en el campo de Learning Analytics (LA). No obstante, la investigación sobre cómo la visualización de estas predicciones puede ayudar a los estudiantes a autorregular su aprendizaje sigue siendo limitada. Este estudio investiga la precisión de modelos predictivos basados en datos académicos, demográficos y de admisión para anticipar el rendimiento de estudiantes de ingeniería durante los primeros dos años, y examina su influencia en la reflexión de los estudiantes sobre decisiones académicas futuras. Utilizando datos del Dashboard de Learning Analytics TrAC y de una base de datos externa, se evaluaron diversos modelos de Machine Learning. Se desarrolló una visualización de predicción integrada en TrAC y se evaluó su influencia en la expectativa de dificultad, percepción de preparación previa, expectativa sobre la carga de estudio y la ansiedad del estudiante. Los resultados indican que la clasificación binaria de aprobación o reprobación es el enfoque más efectivo para predecir el rendimiento en este contexto, mientras que las variables demográficas, de admisión y carga académica no mejoraron significativamente el modelo. La visualización desarrollada muestra la probabilidad de aprobar una asignatura, incluyendo la calidad de la predicción basada en la exactitud del modelo. Un estudio preliminar con estudiantes, realizado a mitad de semestre, muestra que la visualización del modelo predictivo puede reducir la expectativa de dificultad, aunque no influye significativamente en los demás factores evaluados. Sin embargo, hay indicios de que este efecto puede ser más pronunciado para los estudiantes con una probabilidad de aprobación superior al 50%; no obstante, se requiere una muestra más grande para confirmar esta tendencia. Es necesario evaluar el impacto de estas visualizaciones al inicio del semestre, ya que su efecto podría ser más significativo antes de que los estudiantes tengan experiencia con estos cursos.

Keywords: Learning Analytics Dashboard · Students Facing Dashboard · Explainable Learning Analytics · Student Performance Models · Student Reflection.

Abstract. In recent years, the prediction of dropout and academic performance has gained interest in the field of Learning Analytics (LA). However, research on how the visualization of these predictions can help students self-regulate their learning remains limited. This study investigates the accuracy of predictive models based on academic, demographic, and admission data to anticipate the performance of engineering students during their first two years, and examines its influence on students' reflection on future academic decisions. Utilizing data from the TrAC Learning Analytics Dashboard and an external database, various Machine Learning models were evaluated. A prediction visualization integrated into TrAC was developed and its influence on students' expectations of difficulty, perception of prior preparation, expectations regarding study load, and anxiety was assessed. The results indicate that binary classification of passing or failing is the most effective approach for predicting performance in this context, while demographic, admission, and academic load variables did not significantly improve the model. The developed visualization shows the probability of passing a course, including the quality of the prediction based on the model's accuracy. A preliminary study with students, conducted in the middle of the term, shows that the visualization of the predictive model can reduce the expectation of difficulty, although it does not significantly influence the other factors evaluated. However, there is evidence that this effect may be more pronounced for students with a probability of passing above 50%; nonetheless, a larger sample is required to confirm this trend. It is necessary to evaluate the impact of these visualizations at the beginning of the semester, as their effect might be more significant before students have experience with these courses.

Keywords: Learning Analytics Dashboard · Students Facing Dashboard · Explainable Learning Analytics · Student Performance Models · Student Reflection.

1. Introducción

La digitalización de las instituciones universitarias ha generado acceso a una amplia variedad, volumen y granularidad de datos estudiantiles. Este fenómeno ha suscitado un creciente interés en el uso del Learning Analytics (LA) para apoyar las operaciones diarias de las universidades [18]. Entre las herramientas más destacadas en este campo se encuentran los Dashboard de Learning Analytics, diseñados para mejorar la percepción y la toma de decisiones mediante la visualización de datos sobre los estudiantes, dirigidos a una amplia gama de partes interesadas, que incluyen profesores y los mismos alumnos [26]. Estos paneles son especialmente relevantes en el contexto del asesoramiento académico, facilitando la comunicación entre asesores y estudiantes. Ejemplos de estos sistemas incluyen LISSA, implementado en la KU Leuven, Bélgica [11], y LADA, implementado en una institución europea y otra latinoamericana [16]. Este trabajo se enfoca en el Dashboard de Learning Analytics conocido como TrAC.

TrAC (Trayectoria Académica y Curricular) es una herramienta de visualización que muestra la trayectoria curricular de un estudiante específico (ver Figura 1). Esta herramienta fue investigada y desarrollada por académicos de la Universidad Austral de Chile, como parte del proyecto LALA (Learning Analytics in Latin America), y es una adaptación de LISSA [11]. En [15] se detallan las funcionalidades y los distintos elementos que componen la interfaz de TrAC, además de los resultados obtenidos al probar un piloto de esta herramienta con profesores dentro de la universidad. En este artículo también se describe la arquitectura de TrAC, que incluye una base de datos con información académica anonimizada de los estudiantes de la universidad que se actualiza periódicamente.

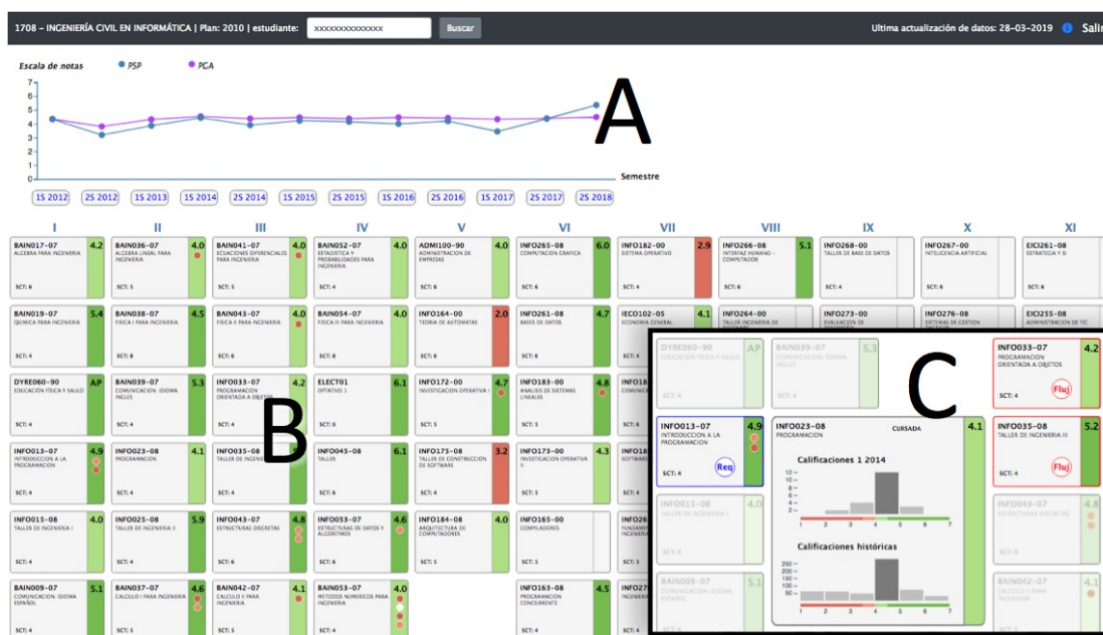


Figura 1. Imagen del sistema TrAC, extraído de [15]

TrAC fue concebida inicialmente para permitir a los directores de carrera de la universidad formarse una opinión informada sobre la situación académica de los estudiantes y respaldar el diálogo con los alumnos, así como las decisiones de los directores de carrera. Posteriormente se otorgó acceso a esta herramienta de forma individual a los estudiantes, lo que les permite visualizar de manera sencilla su trayectoria académica. Esto facilita el suministro de información que permite al estudiante reflexionar de manera más informada, particularmente al finalizar un semestre académico, momento en el que deben planificar las asignaturas que cursarán el siguiente semestre.

Es fundamental que los estudiantes reflexionen sobre las asignaturas que van a cursar, especialmente en contextos como Chile, donde la mayoría de las universidades siguen programas de carreras con una estructura

rígida, determinada por un conjunto fijo de cursos con pocos electivos. Estas asignaturas deben ser cursadas en semestres específicos, y suelen tener una fuerte estructura de prerrequisitos [15].

La falta de dedicación suficiente a esta reflexión puede llevar a algunos alumnos a inscribir la mayor cantidad de cursos posible, con el fin de evitar atrasos en la duración de sus estudios. Esta tendencia puede estar motivada por factores económicos, presión social, expectativas familiares, el deseo de ingresar rápidamente al mercado laboral, entre otros. No obstante, cursar un número excesivo de asignaturas puede tener un impacto negativo en la salud mental de los estudiantes. Según [12], la sobrecarga académica genera más presión y estrés en los estudiantes que otros factores como los problemas familiares y personales. Además, una planificación deficiente puede resultar en una prolongación innecesaria de los estudios. Por lo tanto, es fundamental que los estudiantes reciban herramientas adecuadas y apoyo para elaborar planes de estudio personalizados [4]. En este contexto, la aplicación de técnicas de Machine Learning para prever el rendimiento en asignaturas aún no cursadas puede ser una herramienta valiosa, especialmente para aquellos que toman decisiones sin la orientación de un tutor académico.

Aunque la aplicación de Machine Learning en la educación superior es un tema ampliamente explorado en la literatura, persiste una carencia de investigaciones que aborden de manera efectiva la presentación de la información y el impacto que esto puede tener en los alumnos. Hasta la fecha, solo un número limitado de paneles de Learning Analytics han integrado análisis predictivos [22], y esta cifra se reduce aún más cuando se enfoca exclusivamente en los paneles orientados al estudiante. Además, se ha observado una disparidad en la selección de variables para la predicción entre diferentes investigaciones, lo que ha generado conclusiones contradictorias sobre los factores que influyen en el rendimiento académico, subrayando la necesidad de evaluar estas variables en cada contexto específico.

Un análisis reciente [5] ha sugerido que, aunque las variables demográficas pueden ser útiles para detectar sesgos en los datos y evaluar el rendimiento de un modelo, su utilización como predictores puede tener repercusiones negativas. Además, estudios han resaltado los beneficios de incorporar técnicas de explicabilidad en las visualizaciones resultantes, lo que contribuye a aumentar la confianza en los modelos generados [24]. Por lo tanto, es fundamental prestar atención a la selección de variables que se utilizarán como predictores dentro de los modelos, considerando su relevancia y capacidad explicativa.

El presente estudio aborda el diseño y desarrollo de un algoritmo predictivo diseñado para anticipar el rendimiento académico de los estudiantes en asignaturas que aún no han cursado, utilizando datos disponibles en la Universidad Austral de Chile. Este conjunto de datos incluye información académica proveniente de TrAC, así como datos demográficos y de admisión obtenidos de una base de datos externa. Además, se indaga sobre la influencia que la visualización de estas predicciones ejerce en la reflexión estudiantil respecto a los cursos que seleccionará el próximo semestre. La investigación se lleva a cabo mediante la integración de dicha visualización en TrAC, un Dashboard de Learning Analytics. Para orientar este trabajo, se plantean las siguientes preguntas de investigación:

RQ1: ¿Qué grado de precisión poseen los modelos predictivos, basados en variables académicas de ingreso, desempeño en asignaturas previas y características demográficas, para anticipar el rendimiento académico de los estudiantes durante los dos primeros años de estudios en ingeniería?

RQ2: ¿Cuál es el impacto de la implementación de sistemas predictivos en la reflexión de los estudiantes sobre sus elecciones académicas para el próximo semestre?

Para abordar **RQ1** y explorar los diferentes aspectos del problema, se han formulado las siguientes subpreguntas de investigación:

RQ1.1: ¿Es más conveniente predecir el promedio que obtendrá un alumno en una asignatura mediante métodos de regresión, o utilizar la clasificación para predecir si el alumno aprobará o no dicha asignatura?: Esta subpregunta se incluyó debido a la tendencia en la literatura de utilizar la clasificación para predicciones académicas. Sin embargo, se reconoce que la regresión conserva mejor la información del rendimiento y permite mayor flexibilidad en la presentación de resultados.

RQ1.2: ¿Cuál es el impacto de las variables demográficas en la predicción del rendimiento académico?: La inclusión de esta subpregunta está motivada por la necesidad de evaluar el impacto de las variables demográficas, dado el interés en incluir aspectos de explicabilidad en un trabajo futuro y los efectos negativos que estas variables pueden tener en los usuarios finales.

RQ1.3: ¿Cómo influyen las variables de admisión en la precisión de las predicciones de rendimiento académico?: Dado que estas variables requieren una base de datos externa y considerando los recientes cambios en las pruebas de admisión en Chile, esta subpregunta busca evaluar la contribución de estas variables en la precisión de las predicciones y la necesidad de incluirlas en el modelo.

RQ1.4: ¿Qué efecto tiene la carga académica en la predicción del rendimiento académico?: Esta subpregunta se plantea debido a la escasez de estudios que consideren la carga académica. Además, incluir esta variable complica su futura implementación, ya que requiere conocer todos los cursos que el estudiante cursará para realizar la predicción.

RQ1.5: ¿Cuáles son las variables más relevantes para la predicción de rendimiento por asignatura?: El objetivo de esta subpregunta es maximizar el rendimiento del modelo asegurando que todas las variables utilizadas sean estadísticamente relevantes. Esto ayuda a reducir la complejidad del modelo y facilita la inclusión de explicabilidad en investigaciones futuras mediante un conjunto más reducido de variables.

Para abordar la **RQ2**, se han formulado las siguientes subpreguntas de investigación, las cuales exploran diversas dimensiones de la reflexión estudiantil:

RQ2.1: ¿Cuál es el impacto del sistema predictivo en la percepción de la dificultad de la asignatura por parte del estudiante?: Evaluar el impacto del sistema predictivo en la percepción de dificultad puede revelar si estas herramientas ayudan a los estudiantes a tener una visión más realista y manejable de sus cursos. Una percepción adecuada de la dificultad puede influir en la motivación y la estrategia de estudio, mejorando así el rendimiento académico.

RQ2.2: ¿Cuál es el impacto del sistema predictivo en la percepción de preparación del estudiante para la asignatura predicha?: Comprender cómo el sistema predictivo afecta la percepción de preparación puede indicar si estas herramientas proporcionan información útil que refuerza la confianza del estudiante. Si los estudiantes se sienten menos preparados, pueden tomar acciones preventivas, como repasar contenidos previos, lo que les permitirá enfrentar mejor los desafíos académicos y aprovechar los recursos de aprendizaje de manera más eficaz.

RQ2.3: ¿Cuál es el impacto del sistema predictivo en la percepción de la carga de estudio del estudiante para la asignatura predicha?: Analizar la influencia del sistema predictivo en la percepción de la carga de estudio es esencial para determinar si los estudiantes pueden planificar y distribuir su tiempo de manera más eficiente. Esto puede llevar a una mejor gestión del tiempo y reducir la sobrecarga académica.

RQ2.4: ¿Cuál es el impacto del sistema predictivo en la ansiedad del estudiante respecto a la asignatura predicha?: Evaluar el impacto del sistema predictivo en la ansiedad del estudiante es crucial para comprender los efectos emocionales de estas herramientas. La ansiedad académica puede afectar negativamente el rendimiento y el bienestar general de los estudiantes.

Se espera que las respuestas a estas preguntas contribuyan al desarrollo de visualizaciones más efectivas y al estímulo de la adopción de predicciones en los paneles orientados al estudiante. Además, se espera que este estudio sienta las bases para una investigación futura en la que se aplicará explicabilidad a las visualizaciones, comparando los resultados con los obtenidos en este estudio. La explicabilidad ha demostrado ser capaz de generar una mayor confianza en los modelos y mejorar la interpretación de los resultados en contextos similares.

El resto de este estudio se organiza de la siguiente manera: La Sección 2 revisa trabajos relacionados con la predicción del rendimiento académico y el estudio de diferentes formas de visualización. En la Sección 3, se describe la metodología empleada para el desarrollo y evaluación, tanto de los algoritmos predictivos, como la forma de visualización. Los resultados obtenidos se presentan en la Sección 4. La Sección 5 aborda las discusiones derivadas de los hallazgos. Finalmente, la Sección 6 presenta las conclusiones del estudio.

2. Trabajos relacionados

2.1. Predicción de rendimiento académico

La aplicación de Machine Learning en la educación superior es un área de investigación bastante explorada y con enfoques variados. Algunos estudios tratan la predicción del rendimiento académico como un problema

de clasificación, determinando si un estudiante aprobará o no una asignatura [14], mientras que otros lo abordan como un problema de regresión, anticipando las calificaciones numéricas de una o más asignaturas [9,19,23,25]. En la revisión sistemática realizada en [7], se analizaron más de 260 estudios publicados en los últimos 20 años sobre la predicción del rendimiento estudiantil. El estudio reveló que la gran mayoría de los trabajos recopilados utilizan métodos de clasificación para predecir dicho rendimiento.

En la investigación del rendimiento académico, las variables influyentes varían entre estudios. Por ejemplo, [8] identifican factores como género, beca alimenticia, discapacidad física, edad, raza/etnia y educación de los padres como determinantes, mientras que [14] descartan el género como un factor significativo. Estos hallazgos sugieren la necesidad de evaluar las variables disponibles en contextos específicos, como las carreras de Ingeniería en la Universidad Austral de Chile.

Sin embargo, existe un consenso generalizado sobre la influencia del rendimiento académico previo en el desempeño futuro. En [9] se destaca la correlación negativa de fracasos académicos previos y edad con el rendimiento, así como la correlación positiva de la educación de la madre y el deseo del estudiante de cursar educación superior. Asimismo, [23] afirma que el éxito en un curso está estrechamente vinculado con el rendimiento en cursos anteriores. Además, [7] señala que los registros académicos, la demografía y el comportamiento de aprendizaje son los mejores predictores del rendimiento académico. Este consenso se ve reforzado por investigaciones adicionales, como [19], [21] y [25], que han obtenido resultados satisfactorios utilizando principalmente datos académicos. Estos hallazgos subrayan la importancia de considerar el historial académico y las características demográficas de los estudiantes.

Un estudio más reciente [5] examina tanto los beneficios como las limitaciones de incorporar variables demográficas en la predicción del rendimiento académico. El análisis concluye que, en términos generales, el uso de variables demográficas para examinar sesgos resulta más beneficioso que emplearlas como predictores dentro de los modelos. Esto se debe a que, si bien estas variables ayudan a detectar sesgos en los datos y, en algunos casos, a mejorar el rendimiento de los modelos, también pueden presentar varios aspectos negativos. Estos incluyen la reducción de la equidad, el refuerzo de creencias sesgada, la disminución de la efectividad del modelo para grupos demográficamente menos representados, y la posibilidad de decisiones sesgadas para individuos que son atípicos dentro de los grupos demográficos. No obstante, se destaca que en casos donde el modelo está destinado a ser utilizado por el propio estudiante, el riesgo de sesgo puede ser menor en comparación con situaciones en las que el modelo se emplea para la toma de decisiones por parte de un tercero.

Tras estudiar los artículos [3], [8], [9], [10], [14], [19], [21], [23] y [25], resulta evidente que muchos de los modelos más utilizados en el ámbito de la clasificación, se alinean con los algoritmos de mayor recurrencia identificados en la regresión y en las revisiones de la literatura [1,2,6,7]. Entre estos algoritmos se encuentran Random Forest (RF), Support Vector Machine (SVM), Decision Tree (DT) y Artificial Neural Network (ANN). A partir de esta convergencia, es razonable concluir que estos modelos son buenas opciones a considerar para ser evaluadas en el contexto de esta investigación. Sin embargo, es importante destacar que la popularidad de los modelos no es la única métrica para considerar su uso. Es fundamental tener en cuenta el contexto específico de la investigación y las características particulares de los datos disponibles.

2.2. Visualización de la predicción

La visualización en el ámbito de la predicción del rendimiento académico es un campo menos explorado en la literatura. En [20] se examinaron ocho formas de representación visual, destacando el interés de los estudiantes en la proyección anticipada de su desempeño en asignaturas futuras (Figura 2). Los estudiantes mostraron preferencia por visualizaciones de rangos numéricos y texto en dos grupos de estudio, resaltando la preferencia de una presentación precisa que incluya la incertidumbre del modelo asociada. Uno de los principales descubrimientos del estudio fue que al variar la forma de mostrar la predicción, genera cambios en la forma en que los estudiantes escogen asignaturas. Además, se sugiere la presencia de un efecto de encuadre que induce a los estudiantes a poner más esfuerzo en la selección de cursos cuando se enfrentan a predicciones más específicas. Sin embargo, es importante señalar que en este estudio, los estudiantes no se enfrentaban a sus datos reales, sino a un caso de prueba.

Por otro lado, en [17] evaluaron una visualización que ilustra tanto la probabilidad de aprobar un curso como la calidad de la predicción (Figura 3). Sin embargo, los resultados revelaron una falta de confianza en el modelo de predicción por parte de los asesores, especialmente en una de las universidades evaluadas.

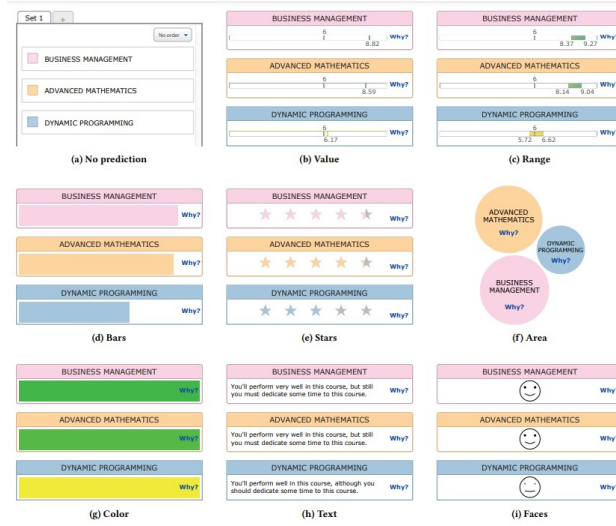


Figura 2. Visualizaciones evaluadas en [20]

Este estudio se diferenció en que la predicción se actualizaba a medida que se seleccionaban asignaturas y se llevó a cabo en sesiones de asesoramiento, lo que sugiere que la percepción de los estudiantes podría variar al enfrentarse individualmente a estas predicciones.



Figura 3. Visualización desarrollada en [17]

En [13] diseñaron una representación visual en forma de distribución normal, que muestra tanto la predicción como la incertidumbre del modelo (Figura 4). Sin embargo, no se extrajeron conclusiones específicas en relación con esta representación visual. Estos estudios subrayan la importancia de explorar más a fondo las formas de visualización en la predicción del rendimiento académico.

Los estudios [17] y [20] resaltan la importancia de incorporar la representación de la incertidumbre del modelo en las visualizaciones de predicción de rendimiento. Este factor es considerado crucial tanto por los estudiantes como por los asesores académicos. Por lo tanto, al desarrollar visualizaciones en este estudio, es esencial tener en cuenta la representación de la incertidumbre del modelo.

Finalmente, en el estudio [24] se investigó el uso de explicaciones interactivas en modelos predictivos de caja negra, con la participación de 13 académicos. Los resultados obtenidos resaltaron que la combinación

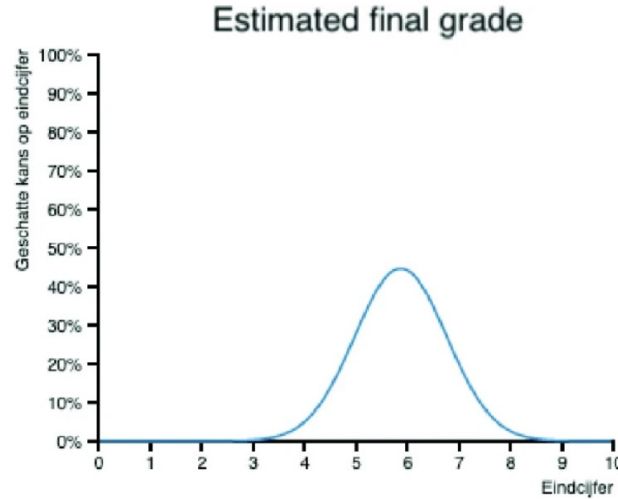


Figura 4. Visualización desarrollada en [13]

de explicaciones junto con simulaciones interactivas, que posibilitaban la manipulación de las características de los estudiantes, permitió a los usuarios comparar o contrastar sus modelos mentales con el modelo de predicción. Esto facilitó una mejor comprensión de cómo las características del estudiante inciden en los resultados del modelo, lo que a su vez permitió identificar características esenciales para recomendar acciones al estudiante.

3. Metodología

3.1. Asignaturas consideradas para la predicción

Para la predicción del rendimiento académico, se optó por seleccionar las asignaturas de bachillerato de matemáticas de las carreras de Ingeniería a partir del segundo semestre. Esta elección se fundamenta en el objetivo de que el estudiante reflexione sobre distintos aspectos, incluyendo la carga académica y el tiempo que le tomará una asignatura, al momento de seleccionar sus cursos para el próximo semestre académico. Aquellos alumnos que ya hayan cursado la asignatura poseen una comprensión previa del esfuerzo y tiempo requeridos. Por otro lado, las asignaturas del primer semestre no se considerarán para la predicción, ya que los estudiantes recién ingresados a la universidad no eligen las materias en esta etapa, sino que se inscriben un conjunto de cursos predefinidos para todos los estudiantes de la misma carrera.

La decisión de realizar la predicción específicamente sobre las asignaturas de bachillerato se basa en las características particulares de la Universidad Austral de Chile. Al ser una institución de tamaño reducido con planes de estudio sujetos a cambios constantes, este enfoque permite trabajar con un conjunto de datos más amplio y estables en el tiempo. Además, se optó por las asignaturas de matemáticas debido a que representan un desafío significativo para los estudiantes de ingeniería. El Cuadro 1 presenta las asignaturas de matemáticas del programa de bachillerato de la Universidad Austral de Chile, detallando el semestre en que se imparten y los códigos de sus prerrequisitos. Como se puede observar, las dos primeras asignaturas corresponden al primer semestre, lo que implica que no se llevará a cabo una predicción para estas.

Finalmente, es crucial destacar que se excluirán del análisis los estudiantes que obtuvieron un promedio final de 1 en estas asignaturas (nota mínima). Esta decisión se basa en que estos estudiantes, aunque inscribieron la asignatura, no la cursaron con el compromiso necesario o no demostraron sus verdaderas capacidades, lo cual introduciría sesgos significativos en la predicción. Asimismo, no se incluirán a los estudiantes que provienen de otras universidades y convalidaron la asignatura a predecir o algún curso del árbol de prerrequisitos, ya que su formación no refleja el contenido y la metodología de enseñanza de la Universidad Austral de Chile, lo que podría afectar la validez de los resultados obtenidos.

| Asignatura | Semestre | Prerrequisitos |
|---|----------|-------------------|
| BAIN065 Álgebra para Ingeniería | 1 | |
| BAIN067 Geometría para Ingeniería | 1 | |
| BAIN073 Álgebra Lineal para Ingeniería | 2 | BAIN065 |
| BAIN075 Cálculo en una Variable | 2 | BAIN065 y BAIN067 |
| BAIN077 Física: Mecánica | 3 | BAIN065 y BAIN067 |
| BAIN081 Ecuaciones Diferenciales para Ingeniería | 3 | BAIN073 y BAIN075 |
| BAIN083 Cálculo en Varias Variables | 3 | BAIN075 |
| BAIN085 Física: Ondas y Electromagnetismo | 4 | BAIN075 y BAIN077 |
| BAIN087 Métodos Numéricos para Ingeniería | 4 | BAIN081 |
| BAIN091 Estadísticas y Probabilidades para Ingeniería | 4 | BAIN073 |

Cuadro 1. Asignaturas de bachillerato de matemáticas de la Universidad Austral de Chile.

3.2. Variables

Las variables que se utilizarán para el ajuste de los modelos comprenderán tanto información extraída de TrAC como información proveniente de una base de datos externa, que incluye variables demográficas e información de ingreso de los estudiantes a la universidad. A cada variable ha sido asignada un código único para facilitar su identificación y referencia durante el análisis. Las variables extraídas de TrAC y sus códigos son:

- **PGA_PRE**: Promedio General Acumulado del semestre previo.
- **PSP_PRE**: Promedio Semestral Ponderado del semestre anterior.
- **PSP_PRE_2**: Promedio Semestral Ponderado de dos semestres anteriores, utilizado únicamente para asignaturas de tercer y cuarto semestre.
- **SCT_ACT**: Carga académica, medida en SCT (Sistema de Créditos Transferibles), al momento de cursar la asignatura a predecir.
- **SCT_PRE**: Carga académica, medida en SCT, del semestre anterior.
- **SCT_PRE_2**: Carga académica, medida en SCT, de dos semestres anteriores, utilizado únicamente para asignaturas de tercer y cuarto semestre.
- **CNG**: Interrupción en los estudios.
- **TMP**: Tiempo transcurrido desde su ingreso a la universidad.
- **ING**: Carrera de ingeniería del estudiante.
- **[código de la asignatura]_PRO**: Promedio obtenido la última ocasión que cursó cada asignatura del árbol de prerrequisitos.
- **[código de la asignatura]_VEC**: Número de veces que ha cursado cada asignatura del árbol de prerrequisitos.

Los datos extraídos de una base de datos externa incluirán las siguientes variables de admisión:

- **ID_PST**: Método de postulación a la universidad, ya sea a través de PSU o PACE.
- **PSU_PND**: Puntaje PSU ponderado obtenido.
- **PSU_LNG**: Puntaje obtenido en PSU de lenguaje.
- **PSU_MAT**: Puntaje obtenido en PSU de matemáticas.
- **PSU_CIE**: Puntaje obtenido en PSU de ciencias.
- **PNT_RNK**: Puntaje Ranking obtenido.
- **PNT_NEM**: Puntaje NEM obtenido.

Desde esta misma base de datos externa se incluirán las siguientes variables demográficas:

- **VLD**: Procedencia geográfica del estudiante, la cual se transformará en una variable binaria que indicará si el estudiante es originario de Valdivia, la ciudad donde se encuentra ubicada la facultad de ingeniería utilizada para este estudio.
- **TIP_EDU**: Tipo de educación escolar del estudiante, que puede variar desde Científico-Humanista vespertino, Científico-Humanista diurno, Comercial, Industrial, entre otros. Esta variable servirá como un indicador proxy del nivel socioeconómico del estudiante.

Es relevante destacar que todas las variables que se utilizarán han sido previamente empleadas o citadas en uno o más estudios, como se detalla en el Cuadro 2. En dicho cuadro se evidencia que la mayoría de los estudios utiliza el desempeño en asignaturas previas para predecir el rendimiento, lo que resalta la importancia de estas variables en el contexto de la predicción académica. Sin embargo, es notable la baja consideración del PGA, la carrera del alumno y el año de ingreso en la literatura existente. La escasa utilización del PGA podría atribuirse al enfoque común en la predicción del primer año, donde este puntaje proporciona información similar al PSP. Además, muchos estudios se enfocan en una carrera específica, lo que hace que la carrera no sea una variable relevante para ellos. En contraste, este estudio se propone abordar todas las carreras de la facultad de ingeniería de la Universidad Austral de Chile, lo que justifica la inclusión de estas variables. Respecto a la baja consideración del año de ingreso, se optó por tratar esta variable como la cantidad de años que el estudiante lleva en la universidad, asegurando así la usabilidad futura de esta variable.

| Estudio | PGA | PSP | Carrera del alumno | Desempeño en asignaturas previas | Reprobaciones | Tipo de Admisión | Año de Ingreso | Puntaje de Ingreso | Datos sobre el colegio | Lugar de procedencia |
|---------|-----|-----|--------------------|----------------------------------|---------------|------------------|----------------|--------------------|------------------------|----------------------|
| [25] | | | | X | X | X | | | | |
| [21] | | | | X | X | | | | | |
| [14] | | | X | | | | | | X | |
| [7] | X | X | | X | | | | | | X |
| [3] | | X | | X | X | | | | | |
| [10] | | X | | | | X | | X | | X |
| [19] | | | | X | | | | | | |
| [6] | | X | | X | | | X | X | | X |
| [1] | X | X | | X | X | | | | X | X |
| [23] | | | | X | | | | | | |
| [2] | | | | X | | | | | | |
| [9] | | | | | | | | | X | X |

Cuadro 2. Artículos que utilizan o citan las variables seleccionadas

Para abordar las subpreguntas planteadas, las variables se agruparán en cuatro conjuntos principales. El primer conjunto incluirá todas las variables disponibles. El segundo conjunto excluirá las variables demográficas, con el objetivo de responder a la **RQ1.2**. El tercer conjunto se compondrá únicamente de las variables específicas de TrAC, con el fin de responder a la **RQ1.3**. Finalmente, el cuarto conjunto examinará todas las variables de TrAC excepto la carga académica, con el propósito de responder a la **RQ1.4**.

Es importante destacar que, aunque todas estas variables sean consideradas, su uso se limitará a evaluar el rendimiento máximo que los modelos pueden lograr. Para el modelo final, se prescindirá de las variables demográficas para evitar los impactos negativos mencionados en [5], y se dará prioridad a aquellas variables que faciliten la creación de visualizaciones explicativas y fomenten la reflexión de los estudiantes sobre sus esfuerzos previos. Este enfoque se anticipa como objeto de estudio futuro, en el que se integrará la explicabilidad a las visualizaciones derivadas de este análisis, en línea con los descubrimientos presentados en [24].

3.3. Modelos de Machine Learning

Para abordar la subpregunta **RQ1.1**, se evaluarán diversos modelos de Machine Learning tanto para la regresión, con el objetivo de predecir el promedio del alumno en una asignatura, como para la clasificación, con el fin de determinar si aprobará o no dicho curso.

En el enfoque de regresión, se probarán los modelos de Multiple Linear Regression (MLR), Polynomial Regression, Artificial Neural Network (ANN), Random Forest (RF), Support Vector Machine (SVM) y Decision Tree (DT), los cuales se evaluarán según el R^2 ajustado obtenido mediante validación cruzada.

Para el enfoque de clasificación, se emplearán modelos tales como Logistic Regression, Naïve Bayes, Artificial Neural Network (ANN), Support Vector Machine (SVM), Decision Tree (DT), Random Forest (RF) y XGBoost, que se evaluarán según el Accuracy obtenido mediante validación cruzada.

Este análisis exhaustivo permitirá determinar cuál de los modelos se ajusta mejor a los datos disponibles, ofreciendo una mayor precisión en la predicción del rendimiento académico.

Para evaluar los diversos grupos de variables y enfoques de regresión y clasificación, se emplearán las asignaturas “BAIN073 Álgebra Lineal para Ingeniería”, “BAIN081 Ecuaciones Diferenciales para Ingeniería” y “BAIN087 Métodos Numéricos para Ingeniería”. Estas asignaturas se seleccionaron por su ubicación en el segundo, tercer y cuarto semestre del plan de estudios de ingeniería, respectivamente. Al abordar materias de distintos niveles académicos, se garantiza una evaluación integral de los modelos propuestos.

Se llevará a cabo una primera selección de variables mediante correlación de Pearson por grupo de variables y asignaturas, con el objetivo de evitar la multicolinealidad. Una vez definido el enfoque y conjunto de variables, estos se aplicarán a todas las asignaturas mencionadas restantes.

Posteriormente, para abordar la subpregunta **RQ1.5**, se llevará a cabo una selección de variables para cada asignatura utilizando un método Forward Selection. Este proceso maximizará el rendimiento del modelo, asegurando al mismo tiempo que todas las variables utilizadas para la predicción sean estadísticamente relevantes.

3.4. Sistema

Para abordar la segunda pregunta de investigación (**RQ2**), se procederá al desarrollo de un prototipo de visualización de la predicción que será integrado en TrAC. Se evaluará el enfoque que presente el rendimiento más óptimo, dado que este aspecto influirá en la manera en que se puede presentar la información, considerando las visualizaciones revisadas en la literatura. Se reconoce que un enfoque de regresión brinda mayor flexibilidad en la presentación de la información; sin embargo, es crucial que las predicciones sean precisas para alcanzar resultados satisfactorios.

En la Figura 1, se observa que TrAC consta de diversas componentes. La parte B muestra la malla curricular del estudiante, y al seleccionar una asignatura, se muestra la parte C de la figura, que presenta un histograma con los promedios históricos de los alumnos en esa asignatura. Por lo tanto, esta sección es ideal para incorporar la visualización de la predicción mediante un botón opcional, con el objetivo de que el estudiante que lo utilice en el futuro esté de acuerdo con ver su predicción.

Además, se incluirá la incertidumbre de la predicción como información adicional para los estudiantes. Esto les permitirá comprender que las predicciones tienen limitaciones y resaltar la importancia de este aspecto, como se subraya en los trabajos [17] y [20].

3.5. Evaluación con estudiantes

Para evaluar el impacto de la visualización de la predicción del rendimiento en la reflexión de los estudiantes al elegir asignaturas, se realizará un laboratorio controlado con alumnos de diversas carreras de ingeniería de la universidad. En este entorno, los estudiantes tendrán la oportunidad de utilizar TrAC y se les pedirá que respondan dos cuestionarios diseñados para medir su reflexión.

El primer cuestionario se administrará al presentar TrAC y explicar sus componentes visuales, permitiendo a los estudiantes familiarizarse con la herramienta y revisar su trayectoria académica. El segundo cuestionario se aplicará después de que se haya incorporado la predicción dentro de TrAC. Esto permitirá observar la variabilidad en las respuestas, lo que ayudará a determinar si existe un impacto y si este es positivo o negativo. Esta evaluación, por limitaciones de tiempo, se llevará a cabo a mediados del semestre académico.

Para abordar las subpreguntas **RQ2.1**, **RQ2.2**, **RQ2.3** y **RQ2.4**, se diseñaron cuatro preguntas específicas para evaluar: la expectativa de dificultad, la percepción de la preparación previa, la expectativa sobre la carga de estudio (medida en horas autónomas por semana) y la ansiedad del estudiante. Estas preguntas serán incluidas en ambos cuestionarios y serán respondidas para cada asignatura de bachillerato de matemáticas que el estudiante esté cursando por primera vez, dado que solo en estas se puede mostrar una predicción. Las preguntas formuladas son las siguientes:

1. ¿Qué tan difícil crees que es para ti esta asignatura?: La respuesta se encuentra en una escala de 1 a 10, donde 1 es muy fácil y 10 es muy difícil.
2. Siento que domino los conocimientos necesarios para cursar la asignatura indicada: Se responde en una escala Likert de 1 a 6.
3. ¿Cuántas horas autónomas por semana estimas que dedicarás a esta asignatura?: Se responde con opciones de 1 a 7, con una opción adicional para 8 o más horas.
4. ¿Cómo te sientes respecto a tu rendimiento en la asignatura?: La respuesta se encuentra en una escala de 1 a 5, donde 1 es tranquilo y 5 es preocupado.

Para analizar si hay una diferencia en las respuestas a estas cuatro preguntas, se utilizará una prueba de rangos con signo de Wilcoxon (Wilcoxon signed-rank test), ya que este es adecuado para datos pareados discretos, permitiendo evaluar los cambios en las respuestas antes y después de ver la predicción. Asimismo, para el primer cuestionario se añadieron preguntas sobre las asignaturas que el estudiante está cursando actualmente

1. ¿Cuántas asignaturas estás cursando este semestre?: Se responde con opciones de 1 a 9, con una opción adicional para 10 o más asignaturas.
2. ¿Cuáles de estas asignaturas de bachillerato estás cursando este semestre?: Se presenta una lista de las asignaturas de bachillerato de matemáticas, donde el estudiante puede seleccionar más de una opción.

En el segundo cuestionario, se incorporó una extensión de las preguntas anteriores, con el propósito de investigar si los estudiantes modificarían el número de asignaturas que cursará al observar las predicciones proporcionadas. Además, se incorporaron preguntas sobre las estrategias que los estudiantes emplearían para mejorar su desempeño en cada asignatura, su nivel de confianza en las predicciones generadas, el impacto de la incertidumbre del modelo en su nivel de confianza, la usabilidad del sistema y su disposición a continuar utilizando la herramienta de predicción:

1. Después de observar las predicciones: Se responde seleccionando una de estas alternativas: a) Consideraría tomar menos asignaturas, b) Consideraría tomar las mismas asignaturas y c) Consideraría tomar más asignaturas.
2. Describe los aspectos de la predicción que te llevaron a reconsiderar la cantidad de asignaturas: Respuesta abierta.
3. Me siento confiado en la predicción que me da el sistema: Se responde por cada asignatura mencionada en una escala Likert de 1 a 6.
4. La calidad de la predicción mostrada por el sistema influye en mi confianza sobre la predicción: Se responde por cada asignatura mencionada en una escala Likert de 1 a 6.
5. Después de observar la predicción, ¿Qué acciones crees que podrías llevar a cabo para mejorar tu rendimiento en la asignatura? : Respuesta abierta.
6. Creo que puedo usar este sistema predictivo sin la necesidad de un entrenamiento especial: Se responde en una escala Likert de 1 a 6.
7. Si TrAC estuviera disponible cada semestre, me gustaría contar con la predicción de rendimiento al momento de decidir sobre las asignaturas que voy a inscribir: Se responde en una escala Likert de 1 a 6.

4. Resultados

4.1. Análisis de enfoques de regresión y clasificación

La cantidad de datos disponibles para ajustar los modelos se detalla en el Cuadro 3. Se observa un aumento sustancial en la cantidad de datos al utilizar exclusivamente la información de TrAC, llegando hasta un 57.6 % de datos adicionales en el caso de “BAIN087 Métodos Numéricos para Ingeniería”. Este incremento se atribuye a que los datos extraídos de la base de datos externa incluyen información únicamente a partir del año 2017, lo que restringe la cantidad de datos disponibles.

Para responder a **RQ1.1**, inicialmente se empleó un enfoque de regresión con el propósito de predecir el promedio final que un alumno obtendrá al cursar por primera vez las asignaturas mencionadas. Sin embargo, los resultados obtenidos no fueron satisfactorios. En el Cuadro 4 se presentan los R^2 ajustado obtenidos

| Datos | BAIN073 | BAIN075 | BAIN077 | BAIN081 | BAIN083 | BAIN085 | BAIN087 | BAIN091 |
|-----------------------|---------|---------|---------|---------|---------|---------|---------|---------|
| TrAC | 1382 | 1335 | 1334 | 927 | 916 | 836 | 684 | 864 |
| TrAC + datos externos | 979 | 942 | 940 | 629 | 612 | 563 | 434 | 568 |

Cuadro 3. Número de datos según las fuentes de extracción.

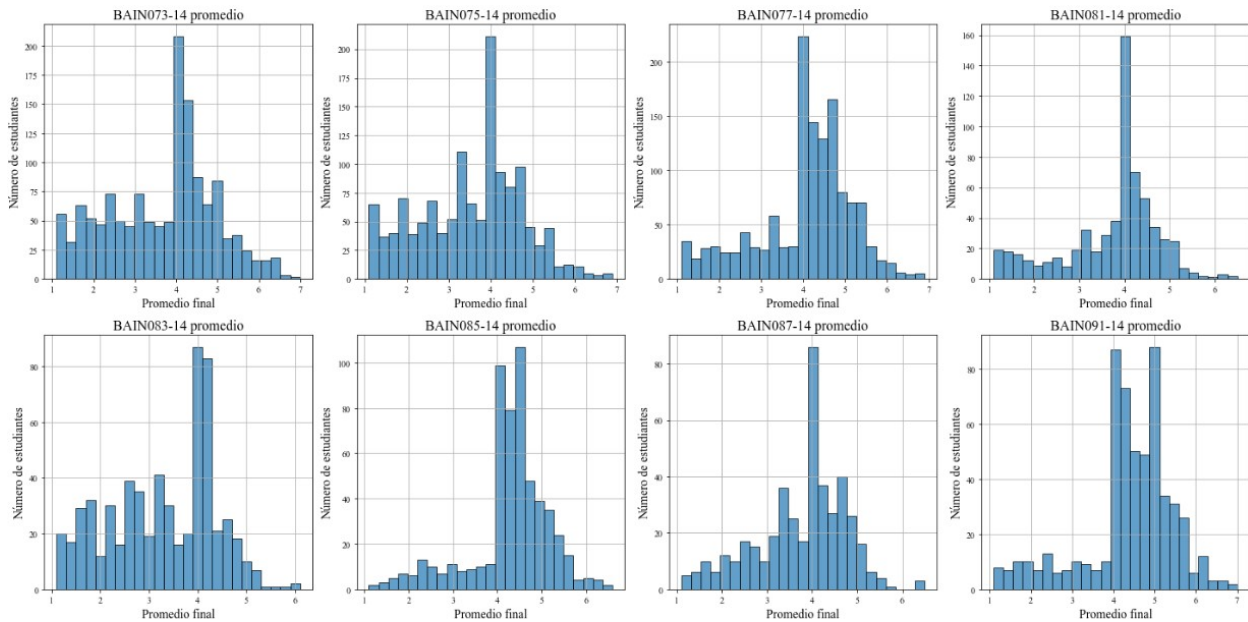
a partir de los modelos que utilizan el conjunto de datos con todas las variables de TrAC, sin incluir la carga académica. Los valores destacados indican los mejores rendimientos alcanzados para cada asignatura evaluada. Este conjunto de datos mostró el mejor desempeño en términos de ajuste del modelo. Sin embargo, se observa que ninguna de las asignaturas evaluadas alcanza un R^2 ajustado superior a 0.3, con un máximo de 0.289 registrado en la asignatura “BAIN073 Álgebra Lineal” y un mínimo de -0.021 en la asignatura “BAIN087 Métodos Numéricos”.

| Modelo | BAIN073 | BAIN081 | BAIN087 |
|---------------------------------|--------------|--------------|---------------|
| MLR | 0.28 | 0.147 | -0.051 |
| Polynomial Regression (grado 2) | 0.289 | 0.142 | -0.065 |
| ANN | 0.19 | 0.115 | -0.067 |
| SVM | 0.25 | 0.108 | -0.051 |
| DT | -0.494 | -0.75 | -1.044 |
| RF | 0.157 | 0.111 | -0.021 |

Cuadro 4. R^2 ajustado obtenidos al utilizar todas las variables TrAC, sin incluir la carga académica.

La ineficacia del enfoque de regresión sugiere que no es adecuada para el presente estudio. Esta incapacidad del modelo puede ser atribuida a las particularidades de las distribuciones de notas en las distintas asignaturas.

La Figura 5 ilustra que, a pesar de que la variable a predecir es continua, existe una marcada concentración de estudiantes con un promedio final de 4.0. Estos estudiantes representan más del 10 % del total en todas las asignaturas analizadas, llegando incluso al 17.33 % en la asignatura “BAIN081 Ecuaciones Diferenciales”.

**Figura 5.** Distribución de datos en las asignaturas consideradas para este estudio.

Esta observación puede explicarse por la existencia de un examen que pueden rendir los estudiantes con un promedio final inferior a 4 y mayor o igual a 3. Si la calificación obtenida en este examen es igual o mayor a 4.0, el estudiante aprueba la asignatura con un promedio final de 4.0, sin importar lo alta que haya sido su nota. Esta política de evaluación contribuye a la elevada concentración de calificaciones en este valor específico, lo que afecta negativamente la precisión y utilidad de los modelos de regresión para predecir los promedios finales de los estudiantes.

Ante los resultados desfavorables obtenidos, se exploró el enfoque de clasificación para determinar la probabilidad de que un estudiante apruebe o no una de las asignaturas mencionadas. Para llevar a cabo este análisis, se procedió a transformar las variables dependientes en binarias, donde un promedio menor a 4 indica que el estudiante reprobará, mientras que un promedio igual o mayor a 4 indica que aprobará (representados mediante 0 y 1, respectivamente). Los resultados derivados de este enfoque no resultaron ser completamente satisfactorios; sin embargo, demostraron ser más viables en comparación con la realización de una regresión. Por esta razón, se optó por este enfoque. Los resultados obtenidos se presentan en la siguiente sección.

Con el fin de explorar la posibilidad de dividir esta clasificación en 3 o más intervalos, para probar distintas formas de proporcionar información a los alumnos, se optó por dividir los datos en intervalos basados en percentiles. Esta elección se fundamenta en la observación de que, de dividirse los intervalos según las calificaciones, se constataría que en todas las asignaturas, sobre el 55 % de los estudiantes obtienen calificaciones comprendidas entre 3 y 5, llegando incluso al 75.66 % en el caso de “BAIN081 Ecuaciones Diferenciales para Ingeniería” (ver Figura 5). Además, en esta última asignatura, menos del 5 % de los alumnos logran un promedio superior a 5, lo que indica un desbalance de datos significativo.

Al dividir los datos en tres intervalos, se observó que ningún modelo logró superar un Accuracy de 0.6, lo que llevó a la decisión de desechar este enfoque. Del mismo modo, se realizaron pruebas dividiendo los datos en cuatro y cinco intervalos, pero se observó que a medida que se aumentaba el número de intervalos, el Accuracy disminuía cada vez más.

4.2. Evaluación de grupos de variables mediante el enfoque seleccionado

Los resultados obtenidos mediante la clasificación binaria para las distintas asignaturas evaluadas se presentan en los Cuadros 5, 6 y 7, utilizando un umbral de probabilidad de 0.5. Al igual que en la sección anterior, los valores destacados indican los mejores rendimientos alcanzados para cada asignatura evaluada. Se puede observar que, en todas las asignaturas evaluadas, el conjunto de datos que incluye las variables de TrAC, junto con las variables de admisión y demográficas, muestra el mejor rendimiento. Sin embargo, este aumento en el rendimiento es poco significativo comparado con el resto de conjuntos evaluados, con un incremento en el Accuracy de tan solo 0.002 en todas las asignaturas. Por lo tanto, al omitir los datos demográficos para evitar los efectos negativos descritos en [5], no se pierde una cantidad sustancial de información en este contexto.

Además, al incluir las variables de TrAC junto con las de ingreso, que se extraen de una base de datos externa, tampoco se observa una mejora significativa en el rendimiento, aumentando un máximo de 0.021 en el caso de “BAIN087 Métodos Numéricos”. Esta baja subida en el rendimiento de los modelos, combinada con el hecho de que al utilizar una base de datos externa se reduce sustancialmente la cantidad de estudiantes con los que se entrenan los modelos y no se garantiza su disponibilidad futura, ha llevado a la decisión de descartar las variables de admisión.

Finalmente, se puede apreciar que las variables de la carga académica no mejoran el rendimiento, alcanzando el mismo desempeño en las asignaturas “BAIN073 Álgebra Lineal” y “BAIN087 Métodos Numéricos” y un rendimiento inferior en la asignatura “BAIN081 Ecuaciones Diferenciales”. Por este motivo, y considerando que la inclusión de estas variables complica la implementación, se optó por utilizar el conjunto de datos que incluye únicamente variables extraídas de TrAC, sin considerar la carga académica.

La Figura 6 muestra las curvas ROC obtenidas de los modelos con mejor rendimiento en las asignaturas evaluadas, utilizando el conjunto de datos seleccionado. En todas las asignaturas, las curvas ROC exhiben un AUC superior a 0.65, lo cual indica una capacidad significativa para distinguir entre estudiantes que aprueban y estudiantes que reprueban. Este resultado supera significativamente el desempeño de un clasificador aleatorio, sugiriendo la efectividad del modelo en esta tarea. Sin embargo, se reconoce que existe un espacio considerable para mejorar la precisión de los modelos.

| Modelo | TrAC, demográficas y admisión | TrAC y admisión | TrAC con carga académica | TrAC sin carga académica |
|---------------------|-------------------------------|-----------------|--------------------------|--------------------------|
| Logistic Regression | 0.689 | 0.7 | 0.68 | 0.683 |
| Naïve Bayes | 0.614 | 0.667 | 0.679 | 0.668 |
| ANN | 0.645 | 0.604 | 0.679 | 0.624 |
| SVM | 0.702 | 0.699 | 0.671 | 0.668 |
| DT | 0.645 | 0.654 | 0.658 | 0.658 |
| RF | 0.688 | 0.688 | 0.684 | 0.684 |
| XGBoost | 0.644 | 0.651 | 0.648 | 0.615 |

Cuadro 5. Accuracy obtenido en los distintos grupos de variable para la asignatura “BAIN073 Álgebra lineal”.

| Modelo | TrAC, demográficas y admisión | TrAC y admisión | TrAC con carga académica | TrAC sin carga académica |
|---------------------|-------------------------------|-----------------|--------------------------|--------------------------|
| Logistic Regression | 0.692 | 0.682 | 0.685 | 0.687 |
| Naïve Bayes | 0.674 | 0.677 | 0.673 | 0.687 |
| ANN | 0.69 | 0.582 | 0.591 | 0.599 |
| SVM | 0.701 | 0.676 | 0.675 | 0.677 |
| DT | 0.658 | 0.641 | 0.685 | 0.699 |
| RF | 0.683 | 0.679 | 0.696 | 0.684 |
| XGBoost | 0.639 | 0.639 | 0.632 | 0.64 |

Cuadro 6. Accuracy obtenido en los distintos grupos de variable para la asignatura “BAIN081 Ecuaciones Diferenciales”.

| Modelo | TrAC, demográficas y admisión | TrAC y admisión | TrAC con carga académica | TrAC sin carga académica |
|---------------------|-------------------------------|-----------------|--------------------------|--------------------------|
| Logistic Regression | 0.585 | 0.583 | 0.595 | 0.595 |
| Naïve Bayes | 0.537 | 0.558 | 0.531 | 0.526 |
| ANN | 0.56 | 0.55 | 0.509 | 0.497 |
| SVM | 0.573 | 0.58 | 0.57 | 0.578 |
| DT | 0.569 | 0.546 | 0.561 | 0.564 |
| RF | 0.618 | 0.616 | 0.585 | 0.593 |
| XGBoost | 0.583 | 0.548 | 0.566 | 0.559 |

Cuadro 7. Accuracy obtenido en los distintos grupos de variable para la asignatura “BAIN087 Métodos Numéricos”.

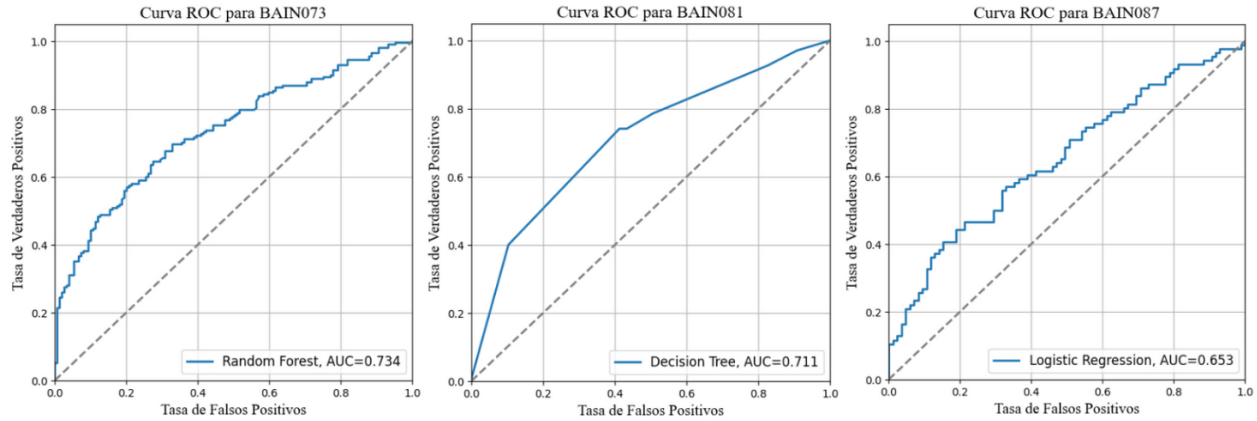


Figura 6. Curvas ROC correspondientes a los mejores modelos de las asignaturas evaluadas.

El Cuadro 8 exhibe el rendimiento de los modelos aplicados a las distintas asignaturas consideradas en este estudio, utilizando el conjunto de variables seleccionado y utilizando un umbral de probabilidad de 0.5. El máximo desempeño se observa en la asignatura “BAIN085 Física: Ondas y Electromagnetismo”, donde el modelo de Support Vector Machine (SVM) alcanzó un Accuracy de 0.839. Por otro lado, el menor rendimiento se registró en “BAIN087 Métodos Numéricos para Ingeniería”, con un Accuracy de 0.595, empleando el modelo de Logistic Regression. Además, se destaca la variabilidad en el rendimiento óptimo de los modelos entre las distintas asignaturas, siendo Logistic Regression y SVM los más sobresalientes al lograr el máximo rendimiento en tres asignaturas cada uno. En contraste, Artificial Neural Network (ANN) y XGBoost no demostraron ser la elección óptima en ninguna de las asignaturas analizadas.

| Modelo | BAIN073 54.12 % aprobación | BAIN075 47.49 % aprobación | BAIN077 71.74 % aprobación | BAIN081 61.37 % aprobación | BAIN083 41.83 % aprobación | BAIN085 81.88 % aprobación | BAIN087 56.68 % aprobación | BAIN091 81.69 % aprobación |
|---------------------|----------------------------------|----------------------------------|----------------------------------|----------------------------------|----------------------------------|----------------------------------|----------------------------------|----------------------------------|
| Logistic Regression | 0,683 | 0,719 | 0,743 | 0,687 | 0,652 | 0,824 | 0,595 | 0,829 |
| Naïve Bayes | 0,668 | 0,697 | 0,752 | 0,687 | 0,642 | 0,345 | 0,526 | 0,405 |
| ANN | 0,624 | 0,673 | 0,731 | 0,599 | 0,633 | 0,743 | 0,497 | 0,777 |
| SVM | 0,668 | 0,723 | 0,735 | 0,677 | 0,652 | 0,839 | 0,578 | 0,827 |
| DT | 0,658 | 0,692 | 0,741 | 0,699 | 0,621 | 0,833 | 0,564 | 0,828 |
| RF | 0,684 | 0,719 | 0,738 | 0,684 | 0,64 | 0,834 | 0,593 | 0,826 |
| XGBoost | 0,615 | 0,669 | 0,721 | 0,64 | 0,637 | 0,809 | 0,559 | 0,81 |

Cuadro 8. Accuracy obtenido en el resto de asignaturas.

El Cuadro 8 también muestra la tasa de aprobación de las asignaturas analizadas. Se observa que la mayoría de las asignaturas exhiben un equilibrio parcial entre los estudiantes aprobados y reprobados. No obstante, se identifica un desequilibrio significativo en las asignaturas BAIN077, BAIN085 y BAIN091, con el 71.74 %, 81.88 % y 81.69 % de los alumnos aprobando, respectivamente. Además, se destaca que en todas las asignaturas, el mejor Accuracy supera la tasa de aprobación, lo que indica que la predicción es más precisa que simplemente basarse en la tasa de la clase mayoritaria. Sin embargo, en las asignaturas con mayor desbalance, esta mejora en la precisión es más limitada.

4.3. Variables seleccionadas por asignatura

Para responder a (RQ1.5), se llevó a cabo la selección de variables empleando el método de Forward Selection. A continuación, se presentan las variables seleccionadas para cada asignatura:

- BAIN073: PGA_PRE, TMP e ING.

- BAIN075: BAIN067_PRO, BAIN065_PRO y BAIN065_VEC.
- BAIN077: PGA_PRE, BAIN067_VEC, BAIN065_PRO e ING.
- BAIN081: PGA_PRE, BAIN067_VEC e ING.
- BAIN083: BAIN075_PRO, BAIN065_PRO, BAIN075_VEC e ING.
- BAIN085: BAIN067_VEC.
- BAIN087: PGA_PRE y BAIN081_PRO.
- BAIN091: PGA_PRE e ING.

El Cuadro 9 presenta el Accuracy obtenido al utilizar exclusivamente las variables especificadas para cada asignatura.

| Modelo | BAIN073 | BAIN075 | BAIN077 | BAIN081 | BAIN083 | BAIN085 | BAIN087 | BAIN091 |
|---------------------|-------------|--------------|--------------|--------------|--------------|--------------|--------------|-------------|
| Logistic Regression | 0.68 | 0.723 | 0.75 | 0.697 | 0.671 | 0.837 | 0.623 | 0.83 |
| Naïve Bayes | 0.653 | 0.702 | 0.737 | 0.649 | 0.64 | 0.807 | 0.599 | 0.206 |
| ANN | 0.67 | 0.706 | 0.73 | 0.656 | 0.643 | 0.834 | 0.632 | 0.819 |
| SVM | 0.676 | 0.725 | 0.759 | 0.693 | 0.654 | 0.837 | 0.639 | 0.822 |
| DT | 0.643 | 0.691 | 0.74 | 0.652 | 0.621 | 0.836 | 0.595 | 0.822 |
| RF | 0.669 | 0.715 | 0.762 | 0.688 | 0.656 | 0.835 | 0.599 | 0.817 |
| XGBoost | 0.63 | 0.687 | 0.726 | 0.646 | 0.625 | 0.837 | 0.56 | 0.776 |

Cuadro 9. Accuracy alcanzado mediante las variables seleccionadas.

Se puede apreciar que, al utilizar exclusivamente estas variables, el rendimiento de los modelos se ve ligeramente afectado, presentando un rendimiento inferior en las asignaturas BAIN073, BAIN081 y BAIN085, y una mejora en el resto de las asignaturas. El cambio más significativo se observó en la asignatura “BAIN087 Métodos Numéricos para Ingeniería”, donde hubo un aumento en el Accuracy de 0.044, llegando a un valor de 0.639 con el modelo SVM; sin embargo, esta asignatura sigue teniendo el menor rendimiento. Por otro lado, el rendimiento más alto se mantiene en la asignatura “BAIN085 Física: Ondas y Electromagnetismo”, aunque descendió a 0.837 con el modelo Logistic Regression.

La mayoría de los algoritmos presentan un rendimiento similar para todos los cursos. Sin embargo, para facilitar la implementación de los modelos a TrAC, se decidió por seleccionar Logistic Regression, ya que en terminos generales, este algoritmo presenta un mejor rendimiento, al ser el mejor en 5 de las 8 asignaturas.

4.4. Visualización de las predicciones

Con el fin de abordar **RQ2**, considerando que el enfoque con el mejor rendimiento implica la clasificación de si un alumno aprobará o no una asignatura de bachillerato por primera vez, y teniendo en cuenta los descubrimientos de [20] que indican la preferencia de los alumnos por representaciones numéricas y concretas, se optó por desarrollar una forma de visualización basada en la probabilidad de aprobación de un alumno determinado en la asignatura a predecir. Esta visualización se fundamenta en la función sigmoide empleada en Logistic Regression. Se adaptó la visualización propuesta por [17], la cual incorpora tanto la probabilidad de aprobación como la incertidumbre del modelo.

La Figura 7 muestra la representación visual desarrollada que se alinea con los estándares de TrAC, exhibiendo la probabilidad de aprobación en formato numérico y mediante un gráfico de progreso circular al igual que en [17]. Asimismo, se incluye la calidad de la predicción, la cual se expresa mediante un texto descriptivo basado en el Accuracy del modelo, clasificado según la siguiente escala:

- Muy Alta: El Accuracy está entre 1 y 0.9.
- Alta: El Accuracy está entre 0.9 y 0.75.
- Media: El Accuracy está entre 0.75 y 0.6.
- Baja: El Accuracy está entre 0.6 y 0.4.
- Muy Baja: El Accuracy es menor a 0.4.

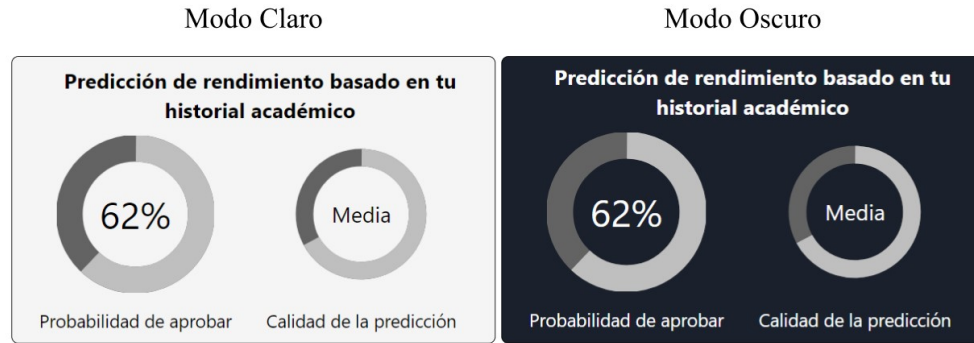


Figura 7. Visualización desarrollada e implementada en TrAC.

Se reconoce la arbitrariedad de esta escala; no obstante, se utiliza para ofrecer una evaluación clara del rendimiento del modelo, lo que mejora la interpretación por parte de los estudiantes.

Además, se tomó la decisión de no revelar las predicciones para estudiantes que no hayan aprobado los requisitos previos, debido a que dichas predicciones se derivarían de calificaciones de reprobación. Esto resultaría en predicciones de aprobación muy bajas, lo que podría impactar negativamente en la motivación de los estudiantes.

Por último, se estableció que las probabilidades de aprobación superiores al 95 % se mostrarían como ">95 %", mientras que aquellas inferiores al 5 % se presentarían como "<5 %". Esta elección se fundamenta en la precaución necesaria al mostrar una probabilidad del 100 % de aprobación, dado que podría generar un exceso de confianza en los estudiantes. Es importante que los estudiantes comprendan que los modelos predictivos son susceptibles a errores. La presentación de porcentajes extremadamente bajos se considera delicada, ya que podría tener un efecto desmotivador en los estudiantes.

4.5. Evaluación del impacto en alumnos

En la sesión de experimentación participaron un total de 16 estudiantes. De estos, 9 pertenecen al programa de Ingeniería Civil en Informática, 3 a Bachillerato en Ciencias de la Ingeniería, 2 a Ingeniería Naval, 1 a Ingeniería Civil Electrónica y 1 a Ingeniería Civil en Obras Civiles. En cuanto a la carga académica, 10 de estos estudiantes se encuentran cursando 6 asignaturas, 3 se encuentran cursando 5 asignaturas, 2 se encuentran cursando 4 asignaturas y 1 se encuentra cursando 3 asignaturas.

La Figura 8 muestra el cambio en las respuestas de los estudiantes a las preguntas diseñadas para evaluar la reflexión en los cuestionarios antes y después de mostrar la predicción. Entre todas las asignaturas, se recolectaron un total de 25 respuestas. Se observa que la pregunta que evalúa la expectativa de dificultad refleja principalmente una disminución en la escala. Por otro lado, la pregunta sobre la ansiedad indica que la mayoría de los estudiantes mantuvieron sus respuestas constantes.

Los p-values obtenidos al aplicar la prueba de rangos con signo de Wilcoxon para evaluar la significancia estadística de los cambios observados fueron los siguientes: 0.0073 para la expectativa de dificultad, 1.0 para la percepción de la preparación previa, 0.6604 para la expectativa sobre la carga de estudio y 0.7389 para la ansiedad del estudiante. Estos resultados indican que, para la expectativa de dificultad, se rechaza la hipótesis nula con un 99 % de confianza, sugiriendo una diferencia significativa que se traduce en una reducción en esta variable al observar la predicción de rendimiento. Para las demás preguntas, no hay evidencia suficiente para rechazar la hipótesis nula, indicando que no existen diferencias significativas en la percepción de la preparación previa, la expectativa sobre la carga de estudio y la ansiedad del estudiante tras observar la predicción.

Para investigar si el cambio en la expectativa de dificultad está vinculado con la predicción proporcionada por el sistema, se dividió a los participantes en dos grupos según la probabilidad de aprobar la asignatura predicha: igual o mayor al 50 % y menor al 50 %. Se aplicó una prueba de rangos con signo de Wilcoxon a ambos grupos, obteniendo un p-value de 0.0109 para el primer grupo y 0.4142 para el segundo. Estos resultados indican que hay una diferencia significativa en la expectativa de dificultad para aquellos con una

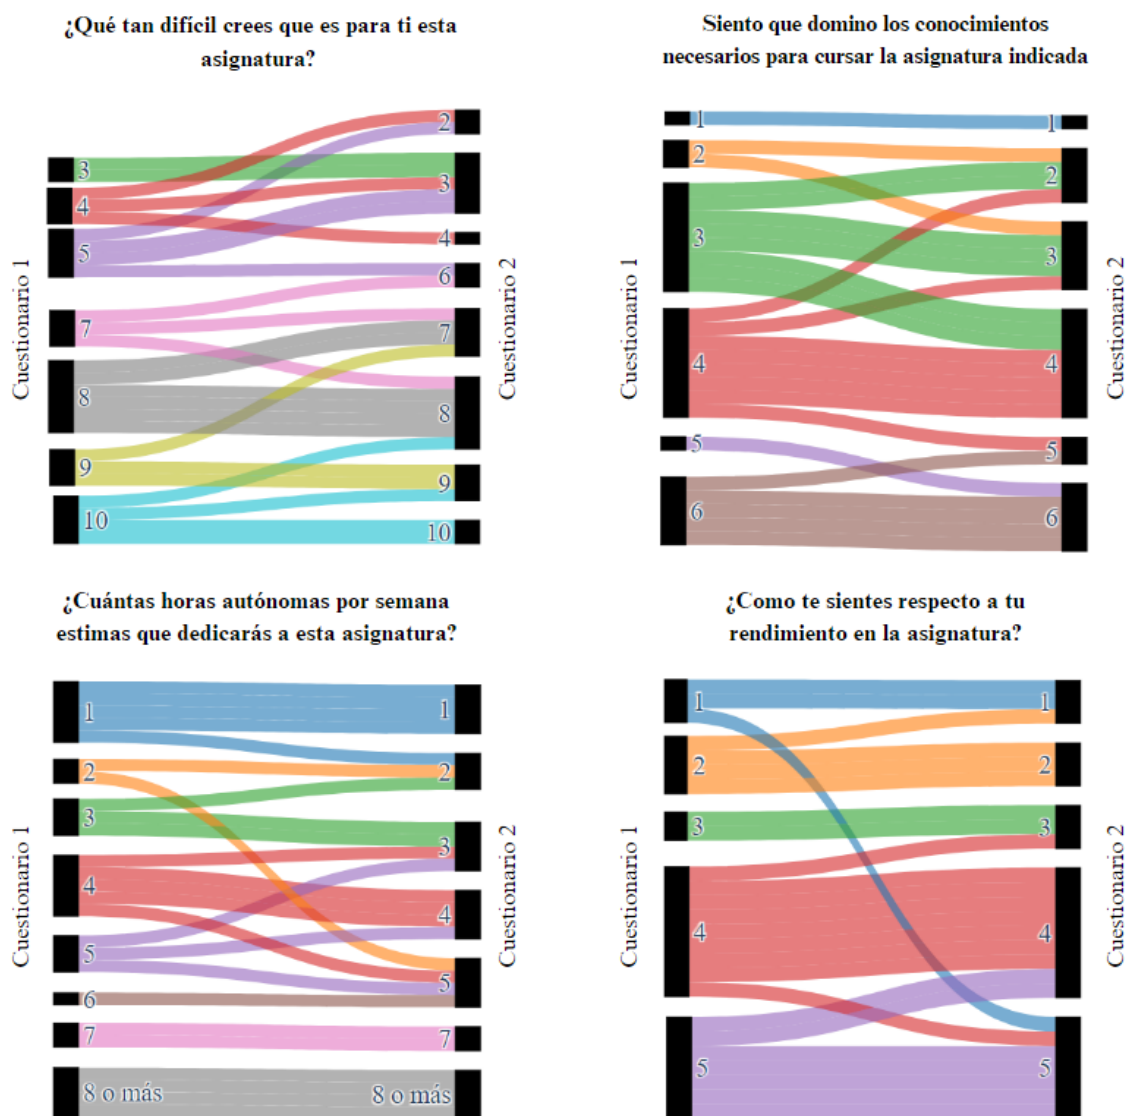


Figura 8. Respuesta de los estudiantes en las preguntas diseñadas para medir la reflexión.

probabilidad de aprobación igual o mayor al 50 %, mientras que no se encontró una diferencia significativa en el grupo con una probabilidad menor al 50 %. Esto sugiere que la predicción influye en la disminución de la expectativa descrita anteriormente.

Para confirmar estos hallazgos, se realizó una prueba U de Mann-Whitney utilizando la diferencia en las respuestas sobre la expectativa de dificultad en cada grupo, obteniéndose un p-value de 0.3004. Este resultado sugiere que, aunque hay una tendencia hacia una diferencia en la expectativa de dificultad entre los dos grupos de probabilidad de aprobación, esta diferencia no es estadísticamente significativa cuando se comparan directamente los dos grupos. Es importante destacar que solo 7 de las 25 respuestas correspondieron a predicciones menores al 50 %, lo que reduce el poder estadístico de la prueba de rangos con signo de Wilcoxon realizada en este grupo y la prueba U de Mann-Whitney para comparar ambos. Además, es importante mencionar que algunas de estas respuestas provienen del mismo estudiante, y otras pertenecen a alumnos que comparten grupo paralelo en la misma asignatura, por lo que los datos no son completamente independientes. A pesar de esto, los hallazgos obtenidos constituyen un análisis preliminar significativo.

Por otro lado, la Figura 9 muestra las respuestas de los estudiantes a las preguntas diseñadas para medir su confianza en las predicciones presentadas. Se puede apreciar que la mayoría de los estudiantes se encuentran medianamente confiados en las predicciones, con una media de respuesta de 4.36 en una escala Likert de 1 a 6. Además, se observa que la calidad de la predicción es un factor importante para los estudiantes, influyendo en su confianza en el modelo, con una media de 4.2 en la misma escala.

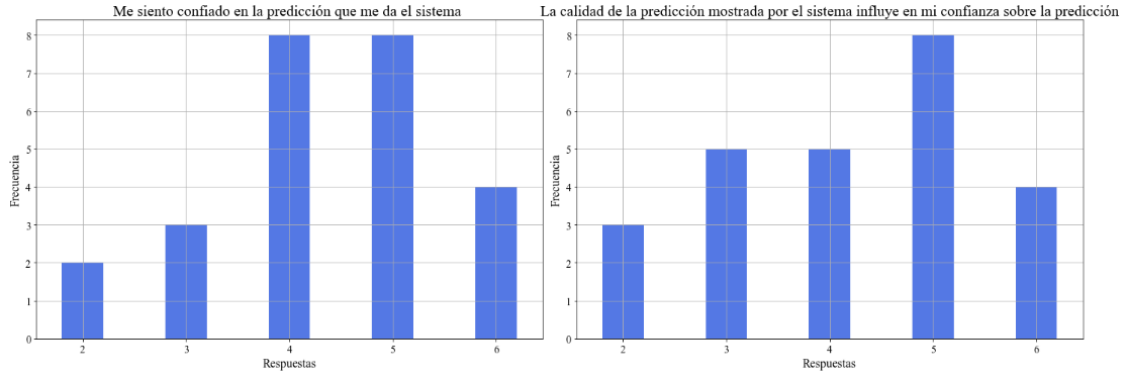


Figura 9. Confianza de los estudiantes en la predicción.

Al preguntar sobre las acciones que podrían llevar a cabo para mejorar su rendimiento en la asignatura, se obtuvieron respuestas como: “dedicarle más horas”, “ir a las ayudantías”, “seguir esforzándome como hasta ahora”, “realizar más horas autónomas por semana”, entre otras. La mayoría de las respuestas indican la necesidad de dedicar más tiempo a la asignatura, lo que demuestra una falta de claridad sobre las acciones concretas que deben realizar antes de tomar la asignatura. Solo tres estudiantes mencionaron que podrían repasar las asignaturas de prerrequisitos para llegar más preparados, pero no especificaron en cuáles enfocarse. Estos resultados resaltan la necesidad de agregar aspectos de explicabilidad a la predicción, con el objetivo de que los estudiantes puedan definir acciones más concretas para mejorar su rendimiento.

En las demás preguntas realizadas, se observó que solo 2 estudiantes considerarían tomar menos asignaturas después de ver la predicción y solo 1 estudiante consideraría tomar más asignaturas. Entre los motivos mencionados se encuentra: “Tomar las asignaturas que tengo mayor porcentaje de aprobación para concentrarme solo en esas”. En cuanto a la usabilidad, la mayoría de los estudiantes consideran que pueden usar el sistema predictivo sin necesidad de un entrenamiento especial. Sin embargo, algunos aspectos generan cierta confusión, reflejado en una media de 4.87 en una escala Likert de 1 a 6. Por último, los estudiantes mostraron un gran interés en contar con la predicción de rendimiento al momento de inscribir asignaturas, con una media de 5.6 en la misma escala.

5. Discusión

Este estudio aborda diversas cuestiones clave en la predicción del rendimiento académico, evaluando múltiples modelos y variables para identificar aquellos que ofrecen mayor precisión, así como el impacto de estas predicciones en la reflexión de los estudiantes.

5.1. Predicción de rendimiento académico

Inicialmente, se investigó la capacidad de los modelos predictivos para anticipar el promedio de calificaciones de los estudiantes en una asignatura específica mediante técnicas de regresión, así como la probabilidad de aprobación o reprobación a través de métodos de clasificación. Los resultados indicaron que la clasificación binaria es el enfoque más viable en este contexto. Este hallazgo puede explicar por qué en [7] la mayoría de los estudios de predicción del rendimiento académico emplean la clasificación, mientras que solo un número

limitado utiliza regresión. Sin embargo, la elección entre clasificación y regresión depende del uso específico de la predicción.

Para evitar los efectos negativos descritos en [5], se ajustaron los modelos utilizando todas las variables disponibles, tanto incluyendo como excluyendo las demográficas. Los resultados mostraron que las variables demográficas no incrementan significativamente el rendimiento predictivo de los modelos, lo que contrasta con los hallazgos de [8], donde se obtuvo un Accuracy de 0.907 utilizando solo atributos demográficos. Esta discrepancia podría deberse a la limitada cantidad de variables demográficas en este estudio y a las variaciones contextuales en la influencia de estas variables sobre el rendimiento académico.

Además, para evaluar la necesidad de incluir una base de datos externa, se ajustaron los modelos utilizando únicamente variables de TrAC y de admisión, así como exclusivamente variables de TrAC. Los resultados mostraron que las variables de admisión tampoco tienen una influencia significativa en la predicción del rendimiento. Esto contrasta con los resultados de [10], donde se observó que los estudiantes con calificaciones de ingreso superiores al 69 % en Biología o al 91 % en Islamiat tenían mayores probabilidades de destacarse en el último semestre de un doctorado en medicina veterinaria. Sin embargo, esta discrepancia puede deberse a las diferencias en las carreras y en el nivel de los estudiantes (postgrado versus pregrado) entre los dos estudios.

Finalmente, se evaluó el impacto de la carga académica en la predicción del rendimiento estudiantil, con el objetivo de simplificar la implementación de los modelos. Los resultados mostraron que la carga académica no mejoró el rendimiento predictivo en ninguna de las tres asignaturas utilizadas para la evaluación. Por lo tanto, se decidió trabajar con las variables de TrAC sin incluir la carga académica. Posteriormente, se realizó una selección de variables con el fin de reducir la complejidad de los modelos y facilitar la explicabilidad en estudios futuros.

Las variables finales seleccionadas para todas las asignaturas incluyeron principalmente la carrera del estudiante, el Promedio General Acumulado (PGA) y la información sobre el rendimiento en algunas asignaturas del árbol de pre-requisitos, como el promedio de calificaciones y el número de intentos. Esto está en consonancia con los resultados de [9], que mostraron que los fracasos académicos previos tienen una correlación negativa con el rendimiento futuro. Además, estos hallazgos se alinean con [7], que indicaron que las calificaciones de los estudiantes son el tipo de entrada más utilizado y que proporciona mejores resultados de predicción, así como con [23], donde se afirma que el éxito en un curso está estrechamente vinculado con el rendimiento en cursos anteriores.

El modelo que mostró el mejor rendimiento general fue la Logistic Regression. Este resultado contrasta con los estudios revisados, donde, aunque este modelo se utiliza en algunos casos, no suele ser el que presenta el mejor rendimiento. Esta observación sugiere que la Logistic Regression puede ser más efectiva de lo que se ha informado previamente en ciertos contextos y con ciertos conjuntos de datos. La discrepancia podría atribuirse a diferencias en la estructura y el contenido de los datos utilizados, así como a la especificidad del contexto académico considerado.

En conjunto, estos resultados destacan la importancia de considerar un conjunto diverso de variables predictoras y de evaluar diferentes algoritmos de manera contextualizada. La variabilidad en los resultados entre diferentes estudios subraya la necesidad de personalizar los modelos predictivos según las características específicas de la población estudiantil y el contexto educativo.

5.2. Impacto del sistema predictivo en la reflexión

Dado que la clasificación resultó ser el enfoque con mejor rendimiento, se desarrolló una visualización basada en la probabilidad de aprobación de un alumno en la asignatura a predecir, adaptando la visualización propuesta por [17]. En esta visualización, la calidad de la predicción se expresa mediante un texto descriptivo basado en el Accuracy del modelo. Posteriormente, esta visualización se integró en TrAC para ser evaluada por los estudiantes.

Para evaluar el impacto en la reflexión de los estudiantes, se consideraron cuatro aspectos principales: expectativa de dificultad, percepción de la preparación previa, expectativa sobre la carga de estudio y ansiedad del estudiante. Estos aspectos se evaluaron mediante dos cuestionarios: el primero se administró al presentar TrAC a los estudiantes y el segundo al incluir la predicción. Además, se añadieron preguntas sobre las asignaturas que el estudiante estaba cursando actualmente, las estrategias que emplearían para mejorar su desempeño en cada asignatura, su nivel de confianza en las predicciones generadas, el impacto de la

incertidumbre del modelo en su nivel de confianza, la usabilidad del sistema y su disposición a continuar utilizando la aplicación.

Los resultados de la prueba de rangos con signo de Wilcoxon indican que la presentación de la predicción de rendimiento tiene un impacto significativo en la expectativa de dificultad de los estudiantes, observándose una tendencia a reducir dicha expectativa. Es crucial investigar más a fondo si esta reducción en la percepción de dificultad se traduce en una mejora real en el rendimiento académico o si pudiese generar una confianza excesiva y una subestimación de los esfuerzos necesarios. Sin embargo, se requiere una muestra más grande de estudiantes para corroborar estos hallazgos de manera robusta. Además, las respuestas analizadas no son del todo independientes, lo que podría influir en los resultados.

El hecho de que no se observara un impacto significativo en la percepción de preparación previa, la expectativa sobre la carga de estudio y la ansiedad sugiere que, aunque los estudiantes perciben las asignaturas como menos difíciles, esto no altera su evaluación de cuán preparados se sienten ni sus expectativas sobre el volumen de trabajo requerido. Esta estabilidad en otras percepciones puede ser vista como positiva, indicando que los estudiantes siguen reconociendo la necesidad de preparación y esfuerzo.

Al analizar las respuestas según la predicción entregada por el sistema, se sugiere que esta puede influir en dicho cambio de expectativa, siendo más notable en los alumnos con una predicción de aprobación mayor al 50 %. Sin embargo, debido al número limitado de datos en el grupo con predicciones menores al 50 %, estos resultados deben interpretarse con precaución debido a su menor fiabilidad estadística. Asimismo, la calidad de la predicción afecta en la confianza de los estudiantes en la misma, lo cual es congruente con investigaciones previas como las de [17] y [20], que enfatizan la importancia de incluir la representación de la incertidumbre del modelo.

La mayoría de los estudiantes consideraron que el sistema predictivo es fácil de usar. Sin embargo, algunos aspectos del sistema generaron cierta confusión. Finalmente, los estudiantes mostraron un gran interés en disponer de la predicción de rendimiento al momento de inscribir asignaturas, alineándose con los resultados de [20].

6. Conclusiones

Este estudio investigó la precisión de modelos predictivos basados en datos académicos, demográficos y de admisión para anticipar el rendimiento de estudiantes de ingeniería durante los primeros dos años (**RQ1**) y evaluó el impacto de estos sistemas en la reflexión de los estudiantes sobre sus decisiones académicas futuras (**RQ2**).

Los resultados mostraron que la clasificación binaria de aprobación o reprobación es más efectiva que la regresión para predecir el rendimiento académico. Las variables más influyentes fueron la carrera del estudiante, el Promedio General Acumulado (PGA) y el rendimiento en asignaturas del árbol de prerequisites, mientras que las variables demográficas, de admisión y la carga académica no mejoraron significativamente la precisión de los modelos.

En cuanto al impacto en la reflexión de los estudiantes, se observó que la visualización de predicciones reduce la expectativa de dificultad sin afectar significativamente la percepción de preparación, la expectativa sobre la carga de estudio y la ansiedad. La mayoría de los estudiantes consideraron el sistema predictivo fácil de usar y mostraron interés en utilizarlo para inscribir asignaturas.

Este estudio presenta varias limitaciones importantes. La cantidad limitada de datos y la posible omisión de variables relevantes debido a su disponibilidad limitada son factores críticos. Además, las predicciones solo se aplicaron sobre asignaturas del bachillerato de matemáticas, lo que podría influir en los resultados si los estudiantes pudiesen ver la predicción para todas las asignaturas de su malla académica. La sesión experimental se realizó a mediados del semestre, cuando los estudiantes ya tenían conocimiento de las asignaturas, lo que podría haber afectado sus percepciones; los resultados podrían diferir si la sesión se realizara antes de la inscripción de asignaturas, por lo que es razonable pensar que esta limitación es importante. La muestra de participantes en la sesión experimental fue pequeña, con solo 25 respuestas de 16 estudiantes, lo que limita la confiabilidad de los resultados.

Para trabajos futuros, se planea realizar la sesión de experimentación a principio de semestre y añadir explicabilidad a las predicciones para fomentar una mayor reflexión y acciones concretas por parte de los estudiantes para mejorar su rendimiento académico. Además, se recomienda ampliar el estudio a diferentes contextos y asignaturas para validar los hallazgos y explorar la efectividad de variables adicionales que

podrían mejorar la precisión de las predicciones. También sería beneficioso realizar estudios longitudinales para observar el impacto a largo plazo de las predicciones en el rendimiento académico y en las decisiones educativas de los estudiantes.

Referencias

1. Amjad Abu Saa, Mostafa Al-Emran, and Khaled Shaalan. Factors affecting students' performance in higher education: A systematic review of predictive data mining techniques. *Technology, Knowledge and Learning*, 24, 12 2019.
2. Ghaith Al-Tameemi, James Xue, Suraj Ajit, Triantafyllos Kanakis, and Israa Hadi. Predictive learning analytics in higher education: Factors, methods and challenges. In *2020 International Conference on Advances in Computing and Communication Engineering (ICACCE)*, pages 1–9, 2020.
3. Sarah Alturki, Lea Cohausz, and Heiner Stuckenschmidt. Predicting master's students' academic performance: an empirical study in germany. *Smart Learning Environments*, 9, 12 2022.
4. Tapio Auvinen, Juha Paavola, and Juha Hartikainen. Stops: a graph-based study planning and curriculum development tool. In *Proceedings of the 14th Koli Calling International Conference on Computing Education Research*, Koli Calling '14, page 25–34, New York, NY, USA, 2014. Association for Computing Machinery.
5. Ryan S. Baker, Lief Esbenshade, Jonathan Vitale, and Shamyia Karumbaiah. Using demographic data as predictor variables: a questionable choice. *Journal of Educational Data Mining*, 15(2):22–52, Jun. 2023.
6. Prasanalakshmi Balaji, Salem Alelyani, Ayman Qahmash, and Mohamed Mohana. Contributions of machine learning models towards student academic performance prediction: A systematic review. *Applied Sciences*, 11:10007, 10 2021.
7. Saba Batool, Junaid Rashid, Muhammad Nisar, Jungeun Kim, Hyuk-Yoon Kwon, and Amir Hussain. Educational data mining to predict students' academic performance: A survey study. *Education and Information Technologies*, 28, 07 2022.
8. Saba Batool, Junaid Rashid, Muhammad Wasif Nisar, Jungeun Kim, Toqeer Mahmood, and Amir Hussain. A random forest students' performance prediction (rfssp) model based on students' demographic features. In *2021 Mohammad Ali Jinnah University International Conference on Computing (MAJICC)*, pages 1–4, 2021.
9. Nicholas Robert Beckham, Limas Jaya Akeh, Giodio Nathanael Pratama Mitaart, and Jurike V Moniaga. Determining factors that affect student performance using various machine learning methods. *Procedia Computer Science*, 216:597–603, 2023. 7th International Conference on Computer Science and Computational Intelligence 2022.
10. Muhammad Bilal, Muhammad Omar, Waheed Anwar, Rahat Bokhari, and Gyu Sang Choi. The role of demographic and academic features in a student performance prediction. *Scientific Reports*, 12, 07 2022.
11. Sven Charleer, Andrew Vande Moere, Joris Klerkx, Katrien Verbert, and Tinne De Laet. Learning analytics dashboards to support adviser-student dialogue. *IEEE Transactions on Learning Technologies*, 11(3):389–399, 2018.
12. Jhon-Franklin Espinosa-Castro, Juan Hernández-Lalinde, Johel E. Rodríguez, Maricarmen Chacín, and Valmore Bermúdez-Pirela. Influencia del estrés sobre el rendimiento académico. *AVFT – Archivos Venezolanos de Farmacología y Terapéutica*, 39(1), May 2020.
13. Damien S. Fleur, Wouter van den Bos, and Bert Bredeweg. Learning analytics dashboard for motivation and performance. In Vivekanandan Kumar and Christos Troussas, editors, *Intelligent Tutoring Systems*, pages 411–419, Cham, 2020. Springer International Publishing.
14. Rodrigo Fonseca Silveira, Maristela Holanda, Guilherme N. Ramos, Marcio Victorino, and Dilma Da Silva. Analysis of student performance and social-economic data in introductory computer science courses at the university of brasília. In *2022 IEEE Frontiers in Education Conference (FIE)*, pages 1–8, 2022.
15. Julio Guerra, Eliana Scheihing, Valeria Henriquez, Cristian Olivares Rodríguez, and Henrique Chevreux. *TrAC: Visualizing Students Academic Trajectories*, pages 765–768. 09 2019.
16. Francisco Gutiérrez, Karsten Seipp, Xavier Ochoa, Katherine Chiluiza, Tinne De Laet, and Katrien Verbert. Lada: A learning analytics dashboard for academic advising. *Computers in Human Behavior*, 107:105826, 2020.
17. Francisco Gutiérrez, Karsten Seipp, Xavier Ochoa, Katherine Chiluiza, Tinne De Laet, and Katrien Verbert. Lada: A learning analytics dashboard for academic advising. *Computers in Human Behavior*, 107:105826, 2020.
18. Rogers Kaliisa, Ioana Jivet, and Paul Prinsloo. A checklist to guide the planning, designing, implementation, and evaluation of learning analytics dashboards. *International Journal of Educational Technology in Higher Education*, 20, 05 2023.
19. Xuansheng Lu, Yanmin Zhu, Yanan Xu, and Jiadi Yu. Learning from multiple dynamic graphs of student and course interactions for student grade predictions. *Neurocomputing*, 431:23–33, 2021.

20. Gonzalo Mendez, Luis Galárraga, and Katherine Chiluiza. Showing academic performance predictions during term planning: Effects on students' decisions, behaviors, and preferences. In *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*, CHI '21, New York, NY, USA, 2021. Association for Computing Machinery.
21. Aya Nabil, Mohammed Seyam, and Ahmed Abou-Elfetouh. Prediction of students' academic performance based on courses' grades using deep neural networks. *IEEE Access*, 9:140731–140746, 2021.
22. Gomathy Ramaswami, Teo Susnjak, Anuradha Mathrani, and Rahila Umer. Use of predictive analytics within learning analytics dashboards: A review of case studies. *Technology, Knowledge and Learning*, 28:1–22, 08 2022.
23. Mohamed Ibrahim Saffeer Muhammad Khan and Syed Ali Haider. Performance prediction of computer science students in capstone software engineering course through educational data mining. In *2021 ASEE Virtual Annual Conference Content Access*, number 10.18260/1-2-37575, Virtual Conference, July 2021. ASEE Conferences. <https://peer.asee.org/37575>.
24. Hanne Scheers and Tinne De Laet. Interactive and explainable advising dashboard opens the black box of student success prediction. In Tinne De Laet, Roland Klemke, Carlos Alario-Hoyos, Isabel Hilliger, and Alejandro Ortega-Arranz, editors, *Technology-Enhanced Learning for a Free, Safe, and Sustainable World*, pages 52–66, Cham, 2021. Springer International Publishing.
25. Maria Tsiakmaki, Georgios Kostopoulos, Giannis Koutsonikos, Christos Pierrakeas, Sotiris Kotsiantis, and Omiros Ragos. Predicting university students' grades based on previous academic achievements. In *2018 9th International Conference on Information, Intelligence, Systems and Applications (IISA)*, pages 1–6, 2018.
26. Katrien Verbert, Xavier Ochoa, Robin De Croon, Raphael A. Dourado, and Tinne De Laet. Learning analytics dashboards: the past, the present and the future. In *Proceedings of the Tenth International Conference on Learning Analytics & Knowledge*, LAK '20, page 35–40, New York, NY, USA, 2020. Association for Computing Machinery.