

# Estudio preliminar para la detección automática del comportamiento antipredatorio en ovinos basado en Redes Neuronales Recurrentes \*

Paula Mancilla<sup>1</sup>, Claudia Letelier<sup>2</sup>, and Pablo Huijse<sup>1</sup>

<sup>1</sup> Instituto de Informática, Facultad de Ciencias de la Ingeniería, Universidad Austral de Chile

<sup>2</sup> Facultad de Ciencias Veterinarias, Universidad Austral de Chile  
[paula.mancilla@alumnos.uach.cl](mailto:paula.mancilla@alumnos.uach.cl)  
[claudialetelier@uach.cl](mailto:claudialetelier@uach.cl)  
[pablo.huijse@uach.cl](mailto:pablo.huijse@uach.cl)

**Resumen** Una de las principales causas de mortalidad en ganadería ovina es la depredación, teniendo como consecuencias pérdidas tanto del bienestar integral de los animales, como económicas para el productor. Hasta el momento no existe un método eficaz para prevenir o mitigar la depredación. Trabajos previos, donde se analizaron manualmente el comportamiento antipredatorio de los ovinos, mostraron que existen factores claros asociados al avistamiento del depredador. El objetivo de este trabajo es emplear las tecnologías de la industria 4.0 para detectar cambios en el comportamiento antipredatorio de las ovejas de forma automática, como un primer paso hacia un sistema de gestión de alertas de comportamiento inusuales en ovinos. Para esto, se propone entrenar un modelo basado en redes neuronales recurrentes (RNN) para clasificar el comportamiento ovino en comportamiento normal o comportamiento antipredatorio, en base a datos de sensores. Estos sensores incluyen un acelerómetro y giroscopio tri-axial y un sistema para medir la cercanía entre ovinos basado en el estándar bluetooth low energy (BLE). Los sensores fueron montados sobre collares y puestos en los animales, de los cuales se recolectaron datos cuando fueron expuestos y no expuestos a un predador canino. Los resultados experimentales demuestran que es posible clasificar el comportamiento antipredatorio y diferenciarlo del comportamiento normal (de base) del ovino, con un modelo simple basado en GRU, permitiendo realizar algún novedoso sistema que permita alertar oportunamente a los granjeros cuando se presente este comportamiento antipredatorio, el cual permitiría tomar las acciones necesarias para resguardar al animal y rebaño del ataque del predador.

**Keywords:** Activity classification · Behavior Model · Sheep · predation · Ruminants · Welfare · Gated recurrent unit · In-situ classification · Precision livestock farming · Wearable sensors.

---

\* Supported by Fundación para la Innovación Agraria.

## 1. Introducción

Los avances en ingeniería y la disminución de los costos de las nuevas tecnologías electrónicas han permitido el desarrollo de muchas soluciones basadas en sensores para la industria ganadera [19]. Estos sensores son capaces de colectar datos automáticamente y en tiempo real, permitiendo así la temprana detección de problemas específicos (ej. pérdidas en la producción, problemas de salud, amenazas para el bienestar) a nivel grupal o individual [8][26][27]. Este enfoque tecnológico se conoce actualmente como ganadería de precisión [9][6].

Por otro lado, las modificaciones del comportamiento normal de los animales pueden reflejar una respuesta adaptativa a un problema o ser una señal a una situación en específico y puede ser de gran ayuda a la hora de tomar decisiones, siendo más relevante cuando se aplica a un grupo importante de animales, como podría ser un rebaño. Sin embargo, la evaluación visual del comportamiento de los animales tiene numerosas limitaciones, como el tiempo, la disponibilidad de mano de obra y los gastos necesarios para observar a cada animal [10]. La ganadería de precisión y en específico las tecnologías de sensores portátiles y en red ofrecen una solución al permitir la recopilación y el procesamiento automáticos de los datos pertinentes [4]. Los conocimientos y experiencias actuales en agricultura junto con machine learning (ML), deep learning (DL), inteligencia artificial (IA), y la aplicación de simulaciones permiten el desarrollo de sistemas expertos automatizados y en tiempo real [29]. Estas tecnologías podrían proporcionar potenciales soluciones para la gestión de alertas tempranas de anomalías [18], por ejemplo, una alerta temprana de la depredación ovina por ataque de perro.

La depredación del ganado es un gran problema para la ganadería, y se le atribuye como la primera causa de muerte en las ovejerías, lo que en conjunto con el abigeato (robo de animales), son los argumentos principales que mencionan los agricultores para retirarse del rubro, pues esto provoca mermas cada año que llegan a trasformar el negocio en insostenible [34]. Según la “Encuesta del Ganado Ovino” [14], donde se consultaron 2.018 explotaciones, las causas de muerte más recurrentes fueron por causa de depredadores, factores climáticos y estado nutricional de la madre, desplazando motivos como enfermedades, mal manejo de las crías o edad de la madre. Por otro lado, se encuentra el problema de los perros y la tenencia responsable, así como las políticas y leyes actuales que modificaron la Ley de caza y la Ley Cholito complicando aun más el panorama, volviéndolo un conflicto ético-social-ambiental y económico sin resolver, agudizando el conflicto humano-predador. Este conflicto sigue siendo vigente, existiendo ahora nueva evidencia del impacto de los perros sobre la fauna nativa, reabriendo una y otra vez la poca o nula capacidad de encontrar una solución amigable al conflicto.

Para prevenir o mitigar la depredación, existen técnicas de tipo letal y no letales en contra de los carnívoros [34], sin embargo, todas las estrategias hasta ahora conocidas han demostrado tener distintos grados de eficacia, no siendo ninguna completamente efectiva, barata y práctica en su aplicación, lo que ha sido desalentador para los agricultores de pequeños rumiantes [34] y ha ido en desmedro del bienestar de los animales atacados. Además, el seguimiento continuo del

comportamiento del ganado no pueden realizarse mediante simple observación humana [21].

Por otra parte, la respuesta antipredatoria, la cual es un conjunto de comportamientos que realizan los animales para lograr sobrevivir ante la posibilidad de ser cazados por un carnívoro o ante el riesgo de depredación, donde los animales modifican su comportamiento una vez avistado un depredador, realizando cambios en su conducta, como por ejemplo, el tiempo que ocupan vigilando el ambiente, mostrando una fuerte gregariedad, y escapando del depredador corriendo en grupo [34], todas son conductas que producto de las nuevas herramientas tecnológicas, pueden ser monitoreadas con soluciones de agricultura de precisión.

La clasificación automatizada de la actividad del ganado, como la actividad de vigilancia y caminata, puede llevarse a cabo mediante sistemas basados en sensores, típicamente equipados con acelerómetros y/o giroscopios [21]. La utilidad de los datos de acelerometría para construir modelos de machine learning supervisado para clasificar diversas actividades de comportamiento de la fauna y el ganado, en particular el ganado, está bien documentada en la literatura [4].

Hay varias formas de abordar el problema de la clasificación del comportamiento del ganado. Los métodos clásicos de machine learning se han utilizado para controlar el bienestar del ganado, observar la cantidad de alimento ingerido y asignar recursos en las explotaciones. Estos clasificadores son relativamente fáciles de entrenar, tienen un bajo coste computacional y funcionan razonablemente bien en algunos casos [21]. Las redes neurales recurrentes (Recurrent neural networks, RNNs) [20] se han empleado ampliamente para clasificar datos de series temporales en diversas aplicaciones. En el área de la clasificación del comportamiento de ganado animal se ha observado que el uso de modelos basados en RNNs obtienen resultados muy similares que otros dentro del estado del arte basados en redes neurales convolucionales (Convolutional neural networks CNNs), redes totalmente convolucionales (fully convolution network FCN), y redes neurales residuales (ResNet), pero con una importante reducción en el uso de recursos y del tiempo. Esto lo hace adecuado para su aplicación en dispositivos o sistemas embebidos con recursos limitados [36].

El objetivo de este trabajo es la implementación de un clasificador binario para distinguir entre el comportamiento de base y el comportamiento antipredatorio de la oveja usando datos de series temporales de un sensor de unidad de medición inercial. La idea es determinar si los resultados de este estudio sirven como antecedente para llevar a cabo una solución definitiva basada en machine learning, ya que, hasta donde sabemos, no se ha presentado ningún clasificador de este comportamiento en la literatura. Además, en este trabajo se describe la tecnología desarrollada para la extracción de los datos claves para reconocer las actividades que indican un comportamiento antipredatorio.

Las actividades claves que muestra el cambio de conducta en las ovejas atacadas por un predador fueron consideradas en este trabajo, las cuales son vigilancia del ambiente y el desplazamiento [34], estas fueron medidas a partir de datos de sensor de unidad de medición inercial (IMU). El comportamiento de grega-

riedad<sup>3</sup> fue medido a través de un sistema de reconocimiento de dispositivos encontrados dentro de un radio por medio del estándar Bluetooth® low energy (BLE).

Las características extraídas, junto con sus etiquetas de clase de comportamiento asociadas, forman un conjunto de datos etiquetados. Utilizando el conjunto de datos, evaluamos el rendimiento de modelos de machine learning. Los modelos aprendidos pueden almacenarse y utilizarse para la predicción del comportamiento antipredatorio que exhibe la oveja doméstica cuando está frente a la presencia de un posible predador.

El presente trabajo pretende determinar si es posible clasificar, a través de redes neuronales artificiales, el comportamiento antipredatorio del comportamiento normal ovino, basado en las características extraídas.

La principal contribución de este trabajo se resume de la siguiente manera: Se entrena un modelo capaz de distinguir entre los comportamientos antipredatorio y normal del ovino. Además se diseña y evalúa un dispositivo usable por la oveja, capaz de extraer datos que sirven como entrada para el modelo. Esto demuestra que es factible realizar una nueva iteración cuyo objetivo sea mejorar este modelo incrementando su rendimiento y que pueda culminar en la producción de algún novedoso sistema que alerte a los granjeros en tiempo real un ataque por depredador al rebaño —por la detección de comportamiento antipredatorio—, permitiendo que se tomen a tiempo las acciones necesarias para resguardar la vida y el bienestar del animal.

El trabajo está organizado de la siguiente manera: los trabajos relacionados sobre los problemas de clasificación del comportamiento en animales, se presentan en la sección 2, los materiales y métodos son explicados en la sección 3, el dataset es presentando en la sección 3.2 y la implementación del clasificador de comportamiento en la sección 3.3, en la sección 4 se muestran los resultados y su discusión y las conclusiones del trabajo se presentan en la sección 5.

## 2. Trabajo relacionado

La clasificación del comportamiento de los animales a través de sensores mediante machine learning se basa principalmente en trabajos enfocados en ganado bovino. En cuanto a trabajos relacionados a ovinos se encontraron dos, el primero se enfocaron en predecir el parto del animal [18] y en el segundo se desarrolló una herramienta para la detección del comportamiento en ovejas [35]. En esta sección describiremos brevemente los trabajos más significativos con respecto a la clasificación de comportamiento animal y será organizado en dos secciones, clasificación de comportamiento ovino (Sección 2.1) y en otro tipo de animales (Sección 2.2). Además, se describe el estudio sobre el comportamiento antipredatorio de la oveja, cuyos resultados han sido utilizados como línea de estudio base para el desarrollo de este trabajo (Sección 2.3).

---

<sup>3</sup> Comportamiento de los individuos de un grupo donde actúan juntos sin planificación.

## 2.1. Clasificación del comportamiento en ovinos

Gurule et al. [18] buscaron detectar con anticipación los comportamientos relacionados al parto de ovejas maduras. Se utiliza el método de Random Forest [7] y los datos obtenidos de un acelerómetro. Como categorías de clasificación el estudio considera siete comportamientos mutuamente excluyentes : “De pie”, “Acostada”, “Lamiendo cordero”, “Caminando”, “Comiendo”, “Contracciones” y “Lamiendo sal”. Las dos primeras clases se consideran como comportamientos de la macro-categoría “Inactivo”, mientras que los restantes pertenecen a la macro-categoría “Activo”.

Para este estudio se estudiaron 13 ovejas preñadas con una edad media de 3 años ( $\pm 0,3$ ), que fueron monitorizadas durante 30 días. A cada oveja se le colocó un arete fijado con un acelerómetro MEMS tri-axial en su oreja derecha o izquierda. El acelerómetro midió los tres ejes (x, y, z) a una tasa de muestreo de 12.5 Hz, los datos fueron almacenados en una memoria Flash y los datos se rescataron una vez terminado el estudio *in-situ*. Las ovejas fueron controladas durante los 30 días de estudio con cámaras de seguridad impermeables con detector de movimientos capturando vídeos tanto de día como de noche. Se analizaron y etiquetaron los movimientos de las grabaciones 7 días antes del parto, etiquetando los datos de movimientos en lapsos de 1 minuto.

En total se obtuvieron 4.708 datos etiquetados, los cuales se dividieron en los dataset de entrenamiento (70 %) y validación (30 %), para entrenar y validar el modelo, respectivamente. Para la entrenar el modelo de predicción se utilizó el procedimiento PROC HPFOREST[28] de SAS (SAS Institute Inc., NC, USA). Los parámetros utilizados para su construcción fueron

1. 6 para máximo de variables a probar (VARS\_TOTRY)
2. 20 como número máximo de árboles
3. 0.1 para el umbral de poda
4. Índice de Gini como criterio de división.

Los resultados de esta investigación arrojaron que la exactitud de los siete comportamientos predichos a partir de un conjunto de validación independiente fue del 66,7 % de precisión global y la precisión global para la predicción de la actividad fue de 87,2 %.

Umstätter et al. [35] desarrollaron una herramienta automatizada para clasificar comportamiento del ganado ovino a través del uso de sensores de inclinación de cabeceo y balanceo. Los tipos de comportamiento estudiados considerados fueron : “Pastoreo”, “Alimentación”, “Beber”, “Caminar”, “De pie inactivo”, “De pie rumiando”, “Reclinación esternal”, “Reclinación lateral”, “Reclinación esternal rumiando”, “Aseo”.

Para este estudio utilizaron 10 collares de seguimiento GPS, con sensores integrados de *pitch* (inclinación) y *roll* (balanceo). Los datos recolectados se analizaron mediante tres métodos de clasificación : Un análisis de discriminación lineal, un método de árbol de clasificación y un árbol de decisión desarrollado manualmente. Los resultados fueron poco concluyentes para la clasificación de estos

comportamientos, por lo que se refirieron a la combinación de “Comer” y “Pasar” como comportamiento “Activo” y por otro lado, comportamiento “Inactivo” a la combinación de “De pie inactivo”, “Reclinación esternal”, “Reclinación lateral”, “Reclinación esternal rumiando”.

Los tres métodos clasificaron satisfactoriamente las dos categorías principales de comportamiento, incluso en circunstancias distintas, por ejemplo, ovejas en un cobertizo o en el exterior, en un campo o en un pasto en una colina. Se trata de un hecho importante porque demuestra que el enfoque es robusto y que la clasificación del sensor de inclinación puede utilizarse incluso cuando las ovejas se trasladan a distintos tipos de ubicación. Sobre los resultados obtenidos para distinguir entre las dos categorías de comportamiento “activo” e “inactivo” más de 90 % de los resultados fueron clasificados correctamente.

## 2.2. Clasificación de comportamiento en otros animales

Hosseinioorbi et al. [21] exploraron el problema de clasificación de comportamientos en bueyes con una red neuronal profunda. Los datos de entrada son obtenidos a partir de sensores acelerómetro triaxial, magnetómetro y giroscopio puestos en un collar. El dataset fue etiquetado de acuerdo a los comportamiento del buey, las clases consideradas fueron: “Pastoreo”, “Caminata”, “Rumia de pie”, “De pie”, “Acostado”, “Beber”, “Aseo” y “Otros”. La frecuencia de muestreo fue de 50 Hz y el dataset generado corresponde a la duración de 19 horas generándose aproximadamente 3 millones de muestras, utilizando un total de 10 bueyes. Como pre-procesamiento, las series de tiempo de los sensores se filtran para luego aplicar una transformada de Fourier corta obteniendo un espectrograma, es decir, una representación de tiempo-frecuencia. La red neuronal, que consiste de un stack de cuatro capas completamente conectadas, recibe los espectrogramas y retorna un vector de probabilidades de clase. El autor afirma que su método propuesto de clasificación logra un alto rendimiento, con un *f1-score* de 94,9 % para 3 clases de comportamiento y un *f1-score* de 89,3 % para 9 clases de comportamiento.

Arcidiacono et al. [5] realizaron clasificación binaria con un algoritmo de Árbol de Decisión [30], para clasificación de los comportamientos “Comiendo” y “De pie”, con datos obtenidos de un sensor acelerómetro, utilizando la mediana de los valores de aceleración del eje X durante un período de 5 segundos. Este experimento se realizó con un grupo de 15 vacas . Cuyo resultado reportando es un *score-f1* de 94,3 %.

Turfi Kasfi et al. [23] presentaron la aplicación de una Red Neuronal Convolutacional (CNN) para la clasificación de comportamiento de vacas. Los datos son capturados utilizando un collar con sensor acelerómetro con una tasa de muestreo de 10 Hz, en un grupo de 22 vacas, en cuál en un principio se consideraron 9 distintas clases a distinguir [31], sin embargo para aliviar el problema de desbalance de clases se consideraron solamente dos clases “Pastoreo” y “Otros”, y para validar el modelo solo se utilizó un conjunto de prueba de un solo animal. La Red Neuronal Convolutacional utilizada en este trabajo tiene una estructura

con un vector de entrada de 1x60, la primera capa de tamaño 1x60 con 10, tamaño de kernel de 1x5, tiene una capa de convolución, luego un pooling y una capa de clasificación que utiliza la función softmax. Los resultados muestran que el modelo obtuvo una precisión de 82.5 % y un score-f1 de 84,4 %.

En 2023, Liang Wang et al. [36] estudiaron la clasificación del comportamiento animal a partir de datos de acelerómetro utilizando varios modelos de redes neurales recurrentes (RNN). Los datos fueron capturados a partir de ganado de vacunos de carne con dispositivos como collar y arete. Los dispositivos almacenaban las lecturas de un acelerómetro triaxial. La frecuencia de muestreo del dispositivo para collar fue de 50 Hz y de 63 Hz para los aretes. Los cambios de comportamiento observados fueron anotados manualmente y los comportamientos de interés de este estudio fueron: “Pastorear”, “Rumear”, “Descansar”, “Caminar” y “Otros”. Para la clasificación propusieron varios modelos basados en RNNs y compararon su rendimiento con modelos del estado del arte basados en arquitecturas convolucionales. Los modelos fueron evaluados tanto en términos de precisión y de complejidad computacional. Los resultados muestran que para un clasificador de comportamiento animal, los modelos recurrentes basados en GRU tienen una mejor precisión que los modelos recurrentes basados en LSTM. En general, un modelo unidireccional basado en GRU con una capa oculta de 64 es el mejor resultado equilibrando precisión y complejidad de todos los conjuntos de datos considerados en este estudio. Además, este modelo obtuvo una precisión muy cercana a los modelos de arquitectura convolucional, pero con una importante reducción de complejidad computacional y de memoria.

### **2.3. Comportamiento antipredatorio de la oveja**

Schacht [34] estudió el comportamiento antipredatorio en la oveja doméstica, permitiendo con ello demostrar las conductas que se modifican cuando el rebaño está en presencia del depredador. Los resultados indican lo siguiente para las conductas contempladas en este estudio con presencia y ausencia del depredador:

**Elevación de cabeza y comportamiento de vigilancia.** Se observó que las ovejas al divisar al perro, disminuyeron las veces que elevan la cabeza a un solo evento convirtiéndose este netamente en vigilancia, distinguiéndose de una elevación de cabeza en la que pudiesen estar realizando otras actividades que consideren mantener la cabeza en alto (rumiar, sociabilizar, desplazarse, etc.). Por definición, vigilancia es cuando un animal está de pie con su cabeza erguida, mientras mira a sus alrededores, y no está recostado, alimentándose, desplazándose o realizando cualquier otra actividad. La duración de este comportamiento se mantuvo durante la totalidad del tiempo en que los ovinos estuvieron en contacto con el perro, manteniéndose en alerta constantemente, inclusive luego de que el perro fuera retirado del estudio [34].

**Comportamiento de gregariedad.** En el estudio el piño de ovinos se mantuvo en grupo durante todo el experimento, pero la gregariedad, no se observó

durante el tratamiento control. Esto significa que mientras no exista peligro, y aunque mantengan siempre su sociabilidad y cercanía a sus congéneres, los animales tomarán más distancia unos de otros, y así podrán no competir por alimentos, agua o lugares de descanso, pero cuando las ovejas divisaron a los depredadores acercarse a ellas, tanto humanos como al perro, estas reaccionaron siempre mostrando una muy cohesiva gregariedad, disminuyendo al mínimo el espacio entre cada animal según lo observado. Esta estrategia de mayor cohesión del grupo frente al depredador le entrega el beneficio a los animales presa de dificultarle al depredador la tarea de búsqueda y selección de objetivo único [34].

**Vocalizaciones emitidas por el rebaño.** En este estudio no se registraron vocalizaciones por parte de los ovinos asociadas a la presencia o ausencia de depredadores. Ello significa que el rebaño no utilizó ninguna forma de comunicación oral entre los miembros del piño para darse alerta del peligro divisado, ni tampoco fueron utilizadas las vocalizaciones para alertar al depredador de que fue visto [34].

**Pasos y velocidad de desplazamiento.** Los resultados comprobaron el que el ovino aumenta su cantidad de pasos dados por minuto al haber presencia de un perro, y por ende, también aumenta su velocidad de desplazamiento. Esto es implícito de la respuesta de fuga, la cual fue observada en la totalidad de los casos donde ingresó un perro al potrero de experimentación, concordando con todos los estudios que describen la respuesta de fuga para la especie ovina como conducta antipredatoria, donde el animal escapa del peligro corriendo, y además, mientras escapa aumenta la sinuosidad en el camino que recorre, lo que también lleva a efectuar una mayor cantidad de pasos por parte del animal [34].

### 3. Materiales y métodos

#### 3.1. Observación preliminar comportamiento ovino in situ

Para el desarrollo apropiado del objetivo del estudio y poder corroborar la respuesta de los ovinos al depredador, 50 ovejas de raza Austral fueron expuestas a un perro, con el cual se simulo la situación de ataque. La respuesta observada fue monitoreada y documentada. Este estudio preliminar fue realizado en la Estación Experimental Agropecuaria Austral ubicada en el Fundo Santa Rosa de la Universidad Austral de Chile en Valdivia.

Para capturar los momentos alrededor de la exposición del rebaño al perro (depredador), se utilizó una cámara fotográfica digital para obtener imágenes desde una visión lateral, y con un DRON con cámara video-grabadora se obtuvieron imágenes de la visión aérea de la situación. Para ambas capturas de las imágenes se consideraron 3 instantes importantes: previo al ataque, durante el ataque y posterior al ataque.

El instante previo al ataque se puede observar en la Figura 1. Este momento y comportamiento fue definido como comportamiento normal, es decir, donde las ovejas se encontraban realizando actividad de rumia, descansando o pastoreo.

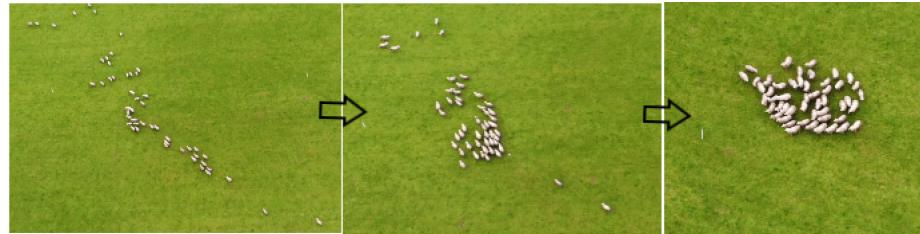


**Figura 1.** Fotografía capturada desde DRON de ovejas mostrando un comportamiento normal.

Para observar el comportamiento antipredatorio de la oveja frente a un depredador, se llevó a un perro doméstico. El propietario del perro condujo al animal durante la experimentación. El can se encontraba contenido por una correa y tirador al momento de ser presentado a las ovejas. Al perro se le incentivó a acercarse a las ovejas y mostrar la conducta predatoria, solo permitiéndosele correr contra ellas.

La respuesta observada desde el primer instante en que el perro se comienza a acercar, y apenas las ovejas lo visualizan, es moverse y dejar de hacer lo que hacían (comer o rumiar). En la Figura 2 se observa este cambio de comportamiento, donde los animales comienzan a caminar para agruparse de manera cohesiva y presentar el comportamiento de gregariedad, llegando a formar un único piñón, además, las ovejas corren intentando alejarse y voltean a visualizar a su predador.

Llevado a cabo la etapa de observación, con los materiales visuales obtenidos se realizaron algunos análisis con el objetivo de calcular las distancias entre ovejas para la implementación del reconocimiento de gregariedad en el dispositivo. Para ello, se realizaron análisis de los fotogramas captados desde la vista aérea con el software Tracker, una herramienta gratuita de modelado y análisis de vídeo [15]. El análisis consistió en modelar una circunferencia de radio de 5 metros, con el centro en cada una de las ovejas del piñón estudiado, simulando así la zona de detección para detectar a otra oveja. Para modelar las distancias, se utilizaron puntos de referencia en distancia que eran conocidas previamente. Todo esto pensando en que la solución a proponer en el estudio, para la detec-



**Figura 2.** Secuencia de fotogramas del piño de ovejas reaccionando ante la aparición del perro.

ción del comportamiento de gregariedad ovina, utilizaría la implementación de detección de cercanía mediante la medición del indicador de fuerza de la señal recibida (Received Signal Strength Indicator, RSSI) de los dispositivos cercanos con Bluetooth Low Energy (BLE).

El RSSI es una medida de la potencia o intensidad relativa presente en una señal de radio recibida en un entorno inalámbrico, y su valor es en decibelio, por lo tanto, cuanto mayor fuera a ser el valor del RSSI (la intensidad), más fuerte sería la señal. Aprovechando la intensidad de la señal, es posible estimar las distancias [13]. En la implementación de la solución, se probó que el RSSI de la señal BLE de los dispositivos utilizados podían medir satisfactoriamente cuando los dispositivos se encontraran a un máximo de 5 metros de distancia entre ellos.

El estudio preliminar permitió determinar las distancias que se presentan en estados de normalidad, como cuando se alteran los patrones de conducta debido a un ataque de un predador, tal y cual se puede observar en la Figura 3, donde se observan la ovejas pastoreando, y donde con el color rojo están marcadas las que detectarían 1 o menos ovejas dentro del rango de detección y en color verde donde se encuentran más de 2 ovejas.

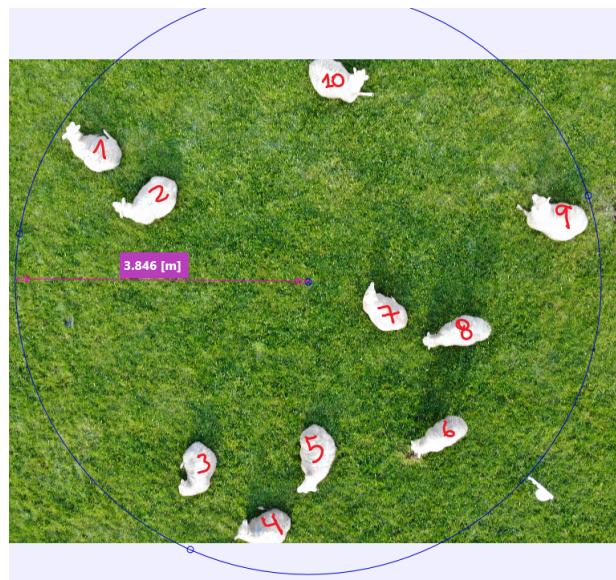
En la Figura 4 se hace un acercamiento de las ovejas que se encuentran rumiando ya que se observan más juntas, donde se puede apreciar que dentro de un radio menor a 5 metros se encuentran 10 ovejas juntas, que corresponde a menos del 20 % del rebaño en observación.

En la Figura 5 se muestra una captura durante la simulación del ataque. El rebaño se encuentra apiñado frente a la presencia del predador y podemos observar el 100 % del rebaño dentro de un radio menor a 5 metros, comprobando así que disminuyen al mínimo el espacio entre cada animal.

Por medio de este trabajo preliminar de observación y análisis se comprueba el cambio de comportamiento mencionado en 2.3. Además, se concluye que una solución basada en medición de distancia en base al RSSI de dispositivos con tecnología BLE podría indicar satisfactoriamente la muy cohesiva gregariedad que presenta la oveja frente a un predador como el perro.



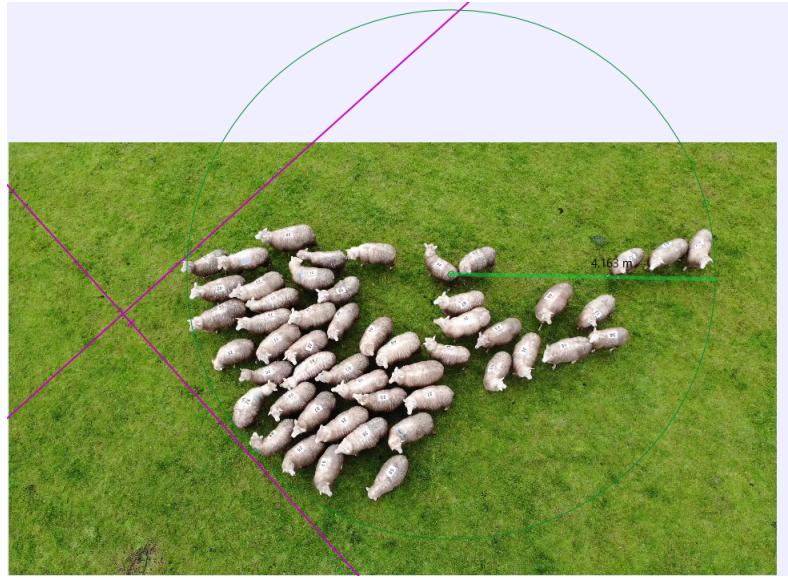
**Figura 3.** Simulación de área de detección de ovejas cercanas en un contexto de comportamiento normal del rebaño.



**Figura 4.** Acercamiento de ovejas con un espacio reducido entre ellas en un contexto de comportamiento normal.

### 3.2. Hardware

El sistema de hardware fue compuesto por 7 tarjetas de desarrollo Pycom LoPy4 equipada con una batería de Litio Ion de 6000 mAh como suministro de energía y una tarjeta de memoria flash microSD de 16 GB, la cuál fue utilizada para almacenar los datos. En este estudio, se utilizó un sensor de unidad de



**Figura 5.** Captura del 100 % del rebaño dentro de una circunferencia de radio menor a 5 metros

medición inercial MPU6050, que combina un acelerómetro de 3 ejes con un rango de escala de  $\pm 2g$  y un giroscopio de 3 ejes con un rango de escala de  $\pm 250^\circ/s$ . El sistema fue montado en un armazón construido con un material bioplástico llamado poliácido láctico (PLA) con una impresora 3D. Fue diseñado para que los componentes queden fijos y resista a los movimientos del animal, y además, a su hábitat natural. El dispositivo fue montado a un collar, posicionándolo en la parte superior del cuello de la oveja y en la parte inferior un contrapeso utilizado para equilibrar el dispositivo y se mantenga en una posición fija.

También al sistema se añadieron 11 tarjetas Arduino Nano RF V3.0 con nRF24L01. Este es una placa con el microcontrolador Atmega 328p que tiene incorporado un módulo inalámbrico nRF24L01. El módulo nRF24L01 es un transceptor de 2,4 GHz de un solo chip, diseñado para aplicaciones inalámbricas de consumo ultra-bajo [24]. El módulo puede funcionar como un *advertising* Bluetooth Low Energy (BLE) de bajo coste, los paquetes que emite el módulo nRF24L01 lo recepta el dispositivo principal con el Pycom LoPy4 con un rango de alcance de 5 metros, comportándose así como una baliza de difusión BLE [16]. Este modulo se integró para poder conocer la cercanía que existe entre las ovejas, de tal manera de que al momento de recibir un paquete del módulo, detecte que existe una oveja cercana y así reconocer el comportamiento de gregariedad ovina, basándonos en el estudio realizado en la Sección 3.1. Este segundo dispositivo se energiza con una batería y se empaquetó en un collar con un bolsillo para que las ovejas las cuelguen de sus cuellos.

### 3.3. Preprocesamiento de los datos

El sensor MPU6050 tiene un giroscopio de tres ejes con el que se mide la velocidad angular y un acelerómetro que calcula la aceleración en los componentes X, Y y Z. El sensor entrega datos crudos, sin ningún tipo de tratamiento o procesamiento, los cuales fueron transformados en información utilizable. Además se debe trabajar con la eliminación del ruido que presentan los datos y la calibración del dispositivo. A continuación se presentan el proceso realizado.

**Filtrado de la señal** El sensor MPU6050 posee un Differential Low Pass Filter (DLPF) programable con seis anchos de banda preconfigurados. Este filtro atenúa las componentes de alta frecuencia de la señal, permitiendo reducir el ruido electrónico de lectura del acelerómetro y del giroscopio. Para este trabajo se consideró un ancho de banda de 5 Hz.

**Calibración del sensor** Normalmente los sensores tienen ciertas diferencias de medición con la realidad. En teoría, un sensor que se encuentra en reposo con el eje Z perpendicular al suelo debería entregar los valores del giroscopio cercanos a 0 en todos los ejes, mientras que el acelerómetro debe dar 0 en los ejes X e Y y valor 1 en el eje Z. La calibración busca que todos los sensores midan siguiendo estos valores teóricos. Para esto se realiza un cálculo de un *offset*.

La calibración del acelerómetro consiste en calcular el *offset* a partir de los primeros 500 datos con el sensor en reposo y un eje perpendicular a la gravedad. Luego, el *offset* de los ejes no perpendiculares es la media de los 500 datos leídos, y el *offset* del eje perpendicular a la gravedad se calcula como la sensibilidad del sensor menos su media. Este *offset* es utilizado para restar cada dato, obteniendo entonces datos calibrados.

**Fusión de sensores** Dada las lecturas del acelerómetro en cada uno de sus ejes ( $A_x$ ,  $A_y$ ,  $A_z$ ), es posible calcular la orientación del sensor. La posición de referencia se toma como la orientación típica de un dispositivo, con los ejes x e y en el plano del horizonte y el eje z ortogonal al horizonte. Como se observa en la Figura 6,  $\theta$  es el ángulo entre el horizonte y el eje x del acelerómetro y  $\psi$  el ángulo entre el horizonte y el eje y del acelerómetro.

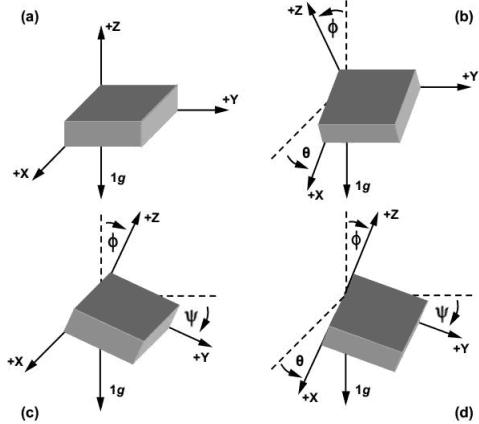
Con trigonometría básica podemos calcular los ángulos de inclinación de los ejes usando las ecuaciones mostradas a continuación.

$$\theta = \arctan\left(\frac{-A_x}{\sqrt{A_y^2 + A_z^2}}\right)[RAD] \quad (1)$$

y

$$\psi = \arctan\left(\frac{A_y}{\sqrt{A_x^2 + A_z^2}}\right)[RAD] \quad (2)$$

El giroscopio permite medir el ángulo de rotación, dado que el giroscopio registra de forma independiente la rotación en  $x$ ,  $y$  y  $z$ , permitiendo determinar



**Figura 6.** Ángulos para la inclinación de los ejes.

la magnitud y dirección de la rotación. Este giroscopio registra la velocidad angular ( $w$ ), que es la relación de variación del ángulo ( $\theta$ ) respecto al tiempo.

$$w = \frac{\delta\theta}{\delta t} \quad (3)$$

Para obtener el ángulo de posición del sensor es necesario realizar la integración respecto del tiempo, por tanto para obtener el ángulo actual en cada uno de los ejes se necesita integrar la velocidad y conocer el ángulo anterior. Esto se hace con las siguientes ecuaciones.

$$\theta_x = w_x^n \cdot dt + \theta_x^{n-1}, \quad (4)$$

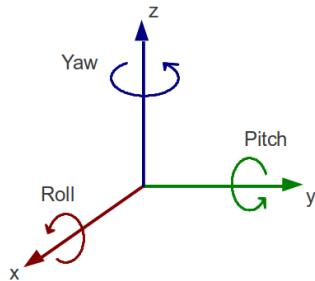
$$\theta_y = w_y^n \cdot dt + \theta_y^{n-1}, \quad (5)$$

$$\theta_z = w_z^n \cdot dt + \theta_z^{n-1} \quad (6)$$

donde  $w_x^n$  es la velocidad angular en el eje  $x$  y en instante  $n$ ,  $dt$  es el paso de integración y  $\theta^{n-1}$  es el ángulo obtenido en el instante anterior.

El sensor acelerómetro se ve influenciado por los movimientos del sensor y el ruido, y el sensor giroscopio obtienen el ángulo por integración respecto al tiempo, por lo que acumula error y ruido en la medición, por lo que pueden generar problemas de deriva (drift), por ello se combinan las mediciones de ambos dispositivos permitiendo a las IMU obtener mediciones de la orientación más precisas.

Los ángulos de navegación, se representan como tres rotaciones ortogonales en torno al eje x (roll), eje y (pitch) y Z (yaw), que se puede ver ilustrada en la Figura 7.



**Figura 7.** Ángulos para la inclinación de los ejes.

Para combinar las mediciones de ambos dispositivos y estimar los ángulos pitch y roll se usó el denominado *Filtro complementario* y el *Filtro de Kalman*.

El Filtro complementario se comporta como un filtro de paso alto para la señal del giroscopio y un filtro de paso bajo para la señal del acelerómetro. Este es un algoritmo relativamente simple, el cual requiere un bajo costo computacional y es de fácil implementación [17]. El filtro complementario puede ser representado como:

$$\text{Ángulo filtrado} = \alpha \cdot (\text{ángulo giroscopio}) + (1 - \alpha) \cdot (\text{ángulo acelerómetro}) \quad (7)$$

$$\alpha = \frac{\tau}{\tau + \delta t}$$

Donde  $\tau$  es la constante de tiempo del filtro.

El valor de  $\alpha$  se definió en base a base pruebas de laboratorio, que consistió en realizar un mismo experimento con distintos  $\alpha$ , buscando el resultado más preciso. El  $\alpha$  utilizado fue de 0,98.

El filtro de Kalman también se aplicó para la fusión de los sensores, este es un filtro iterativo, el cual es eficiente pero requiere un alto costo computacional [17]. La implementación utilizada se puede encontrar en [22], este consiste en un modelo del sistema, el cual se usa para estimar la siguiente medición, que es una distribución de probabilidad y que se utiliza para actualizar la medición real.

Dado que para obtener la medida del ángulo yaw es necesario el uso de otros sensores, los ángulos de inclinación calculados por la fusión del sensor giroscopio y acelerómetro son roll y pitch, almacenando los resultados dados usando el filtro complementario y el filtro de kalman.

### 3.4. Recolección de datos

La recolección de datos se realizó en el plantel ovino del predio Agrícola Colico, ubicado en la comuna de Cunco, Región de la Araucanía, Chile.

Se llevaron a cabo cuatro pruebas experimentales, donde se utilizaron en total 7 dispositivos de detección de comportamiento por medio de sensor IMU y 11 dispositivos con el modulo nRF24L01, el cual es el que se comporta como una baliza de difusión de BLE.

Se utilizó parte del rebaño de ovejas adultas del predio, las cuales eran elegidas al azar en cada experimentación, al pasar por la manga de trabajo, donde se les instaló un collar que llevaba el dispositivo en el cuello de los animales, estos capturaban el comportamiento del animal mientras se encontraban a pastoreo.

Para medir el comportamiento antipredatorio del ovino ante perros, se recrearon cuatro ataques de perro al piño, uno por día de experimentación, estos eventos se realizaron en instantes aleatorios del día. Las simulaciones de ataques se realizaron utilizando un canino mediano, el cual es un animal que anteriormente ha mostrado agresividad hacia el ganado ovino y que ellas no conocían. El perro estaba adiestrado para recibir órdenes de su propietario y detenerse en el momento que se le indicara. El can fue liberado y el dueño del animal le incentivó a acercarse a las ovejas simulando un ataque. Luego de un tiempo de 5 minutos aproximadamente el cánido fue removido del potrero por medio de órdenes del dueño y dejó de ser visible para el rebaño.

En la Figura 8 se observa el dispositivo de medición dispuesto como un collar en la parte superior del cuello del animal.

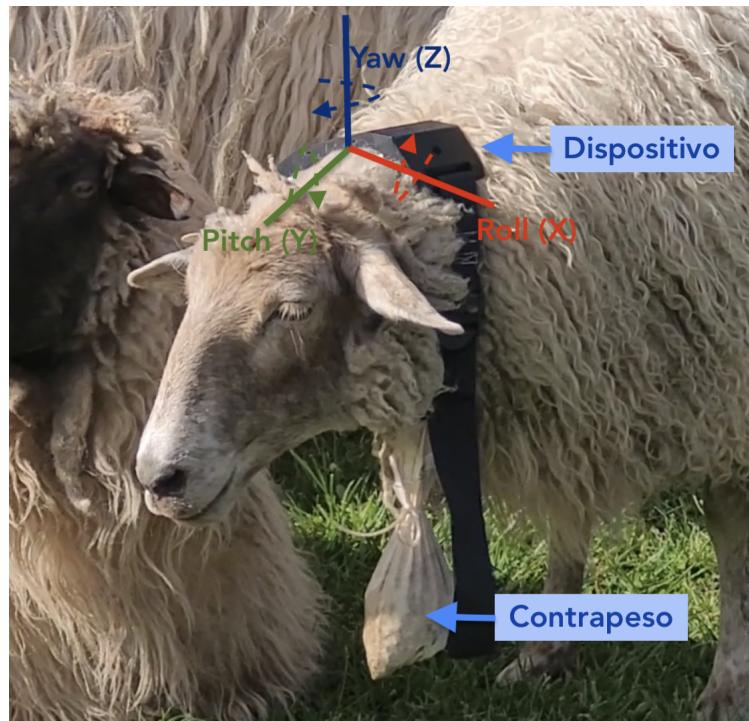
La Figura 9 muestra una fotografía de una parte del rebaño de prueba utilizando el segundo dispositivo con el modulo nRF24L01, el cuál se comporta como una baliza de difusión de *Bluetooth Low Energy* (BLE).

Además del dispositivo instalado en el collar que registraba el comportamiento de las ovejas, en todo momento del experimento un equipo de dos personas vigilaron el desarrollo del estudio registrando los tiempos en que se observó el comportamiento previo a la simulación del ataque, la primera aparición del perro, el inicio y finalización del ataque.

### 3.5. Observación y validación del set de datos

El data set fue etiquetado con dos comportamientos, comportamiento normal, es decir, sin presencia de depredadores y comportamiento antipredatorio, que es el comportamiento una vez avistado un depredador.

Debido al factor investigativo de este estudio, el prototipo desarrollado para la medición de los datos requirió iterarse para la mejora del diseño del prototípo, las cuales advertimos en el instante o terminadas las pruebas in-situ con las ovejas. Algunos de los problemas fueron los siguientes: Inconvenientes en el sistema de amarre y sujeción, ya que algunos collares aflojaban, provocando que los dispositivos se desprendan hacia el suelo en medio del experimento; el material del armazón impreso poco robusto debido a la configuración del grosor de capas en la impresión, provocando que se rompa el armazón; y, la unión de cables a los pines de entradas de tarjeta de desarrollo, que con el movimiento del animal se desconectaban provocando que el dispositivo no almacenase más datos. Por lo que cada una de las pruebas experimentales también permitió revisar la robustez



**Figura 8.** Dispositivo instalado en el cuello de la oveja con sus ejes.



**Figura 9.** Ovejas utilizando el dispositivo con modulo nRF24L01.

del diseño del dispositivo, teniendo que iterar en el prototipo de medición para mejorarlo.

Es importante mencionar que las pruebas experimentales implicaron de un significativo uso de recursos, como el humano, necesitando de la Médico Veterinario para el manejo ovino, del propietario del perro para dar las órdenes, personas para el manejo de las ovejas; las ovejas con el consecuente estrés de los animales y el perro depredador; costo de traslados del equipo, ya que el lugar donde se encuentra el rebaño son sectores rurales a los que se debe llegar en vehículo particular. Además, en este estudio se aplicó el enfoque ético de las Tres R (3R), en español se refiere a la sustitución, reducción y refinamiento de la investigación con animales, formulados por Russel y Burch, en su libro “The Principle of Humane Experimental Technique” [32], por lo que se debió reducir el uso de los animal a experimentar y las veces a repetir el estudio, maximizando la información obtenida por lo animales y tratando de no comprometer el bienestar animal por la realización de muchas pruebas, ya que un ataque les genera estrés, esto implicó que no se pudieran realizar tantas pruebas como las deseadas. Además, por reducir el uso animal para experimentar, se realizaron las pruebas de medición y de robustez de diseño al mismo tiempo, provocando desafortunadamente que varios de los datos capturados no sean útiles para añadirlos dentro del set de datos, lo que implicó que el set de datos sea menor al esperado.

En total, los datos utilizados en este estudio provienen de 11 ovejas, y cada serie de tiempo está etiquetada con  $\theta$  para el tiempo en que la oveja se comportó normalmente y con 1 para el periodo de tiempo en que la oveja mostraba un comportamiento antipredatorio.

### 3.6. Generación de características

Las series de datos capturadas están compuestas por el tiempo de la captura del dato en milisegundos y el dato que entrega el módulo MPU6050, los cuales fueron preprocesados para obtener los ángulos de X e Y del acelerómetro y de X, Y y Z del giroscopio. Además se obtiene el roll y pitch de la fusión de ambos utilizando el Filtro de Kalman y Filtro Complementario explicado en la Sección 3.3. La tasa de muestreo de las mediciones fue de 130 Hz.

Para suavizar estos datos y extraer más información se generaron los siguientes características o *features* a partir de los datos, siendo de dos tipos:

1. Tasa de cambio: Se calculó la tasa de cambio con el varía el roll y el pitch obtenida con el filtro de Kalman, para obtener la velocidad con la que varian los movimientos en el tiempo.
2. Estadísticos: Se añadió al conjunto de datos la *media* y *desviación estándar* del roll y pitch calculados con el filtro de Kalman y los estadísticos de la Tasa de cambio del pitch y el roll, calculado a partir de una ventana de tiempo. Las ventanas de tiempo contempladas en el estudio fueron: 2.6, 5.2, 7.8, 15.6, 30, 40, 60, 120 y 300 segundos. La etiqueta de una ventana de contexto se calcula como la moda de las etiquetas originales. El largo de los

datos luego de realizar la función del enventanado da como resultado F, el cual se calcula como:

$$F = \frac{\text{Largo arreglo} - \text{Largo ventana}}{\text{Stride}}, \quad (8)$$

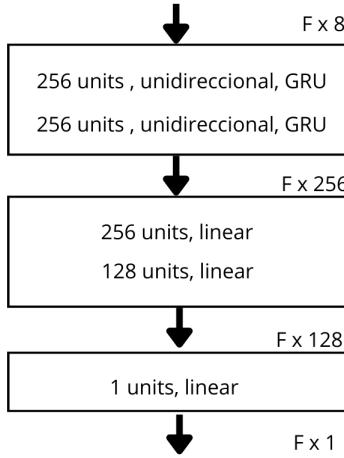
donde Stride es el tamaño del paso

En esta investigación la información del número de ovejas cercanas encontradas, capturadas con el modulo nRF24L01, no fue incluido dentro del set de datos. Esto se debe a la baja cantidad de ovejas que utilizaron este dispositivo con este módulo en relación a la cantidad del rebaño total (al rededor del 20 % rebaño utilizó este dispositivo), provocando que el valor de ovejas cercanas encontradas no sean suficientemente significativo.

### **3.7. Modelo de Red Neuronal para la clasificación del comportamiento antipredatorio ovino**

La estructura del modelo para la predicción de comportamiento antipredatorio de la oveja se ilustra en la Figura 10. Primero las *features* son la entrada de un tipo especial de capa recurrente, específicamente una *Gated Recurrent Unit* (GRU) [12]. Estas capas GRU se especializan en el aprendizaje de estructuras temporales y son más fáciles de entrenar en comparación con otras capas recurrentes. Seguida por dos capas ocultas totalmente conectadas (FC) y la capa de salida del modelo, que corresponde a la predicción de la probabilidad de presentar un comportamiento antipredatorio, obteniendo un elemento en el rango de [0,1]. El modelo discutido recientemente fue implementado utilizando la librería PyTorch[2] de lenguaje Python.

El set de datos de 11 series de tiempo fue separado entre set de entrenamiento y set de prueba. El set de entrenamiento fue escogido por un método no aleatorio, decidiendo la selección de las serie de tiempo según más notorio fuera el cambio del comportamiento de la oveja, tal que se utilizaron 2 series de tiempos de ovejas para el set de entrenamiento y 9 series de tiempo como set de prueba. La función de costo utilizada fue *Binary cross-entropy with logits loss* [1]. Debido a la naturaleza altamente desequilibrada del conjunto de datos ( $\sim 10\%$  de etiquetas son positivas) se añade una ponderación a la función de costo con el parámetro *pos\_weight*. El método de gradiente descendente con paso adaptativo (ADAM) fue utilizado como optimizador [25]. El número máximo de épocas de entrenamiento fue configurado de 200 épocas. También se consideró un *early stopping* para evitar el sobreajuste. El entrenamiento se detenía si el valor de la *loss de prueba* empeoraba dentro de 14 épocas seguidas. En cada época se entrena con en el set de datos de entrenamiento y luego se evalúa con el set de datos de prueba, calculando la *loss* de cada uno de ellos. Se almacena el mejor modelo, comparando la *loss de prueba* obtenido con la mejor *loss de prueba* obtenida por el mejor modelo almacenado en uno de los anteriores entrenamientos.



**Figura 10.** Arquitectura modelo para la clasificación del comportamiento antipredatorio ovino.

El rendimiento del modelo para la clasificación del comportamiento antipredatorio ovino depende de variados hiper-parámetros. Las siguientes combinaciones de hiper-parámetros fueron considerados en la experimentación:

1. El largo de la ventana: 2.6, 5.2, 7.8, 15.6, 30, 40, 60, 120 y 300 *segundos*;
2. La tasa de aprendizaje: 0.0001, 0.0009, 0.003, 0.001, 0.007, 0.01, 0.08 y 0.1;
3. La tasa dropout: Se variaron los valores entre 0, 0.25, 0.5 y 0.75;
4. Añadiendo ponderación a la función de costo con *pos\_weight* o estableciendo *pos\_weight* como *none*

**Métricas y rendimiento** Para medir los resultados del modelo para la clasificación del comportamiento antipredatorio ovino se utilizó la función de *Classification report*, que retorna un reporte escrito de las principales métricas de clasificación, considerando el *F1-score*, *recall* y *precisión*. Para los análisis se utilizaron la función de matriz de confusión, la curva ROC y su área bajo la curva (AUC), importados desde *sklearn.metrics* [3]. También se graficó la curva *Precision - Recall (PR)* que se utilizó por ser un buen indicador del rendimiento de clasificadores con clases desbalanceadas [33]. Para los resultados de predicción del set de datos de prueba se aplicó la función *sigmoide* al vector de predicciones y finalmente una función para redondear, la cuál retorna los valores de predicción de 0 o 1.

#### 4. Resultados y Discusión

La calidad de los resultados experimentales se evaluaron comparando el *F1-score* y observando los resultados gráficos del set de datos de prueba, comparando

los valores de predicción con las etiquetas reales. Los resultados presentados se basan en el mejor conjunto de hiperparámetros, que fueron los siguientes:

- El largo de la ventana: 60, equivalente a *7.8 segundos*;
- La tasa de aprendizaje: 0.01;
- La tasa dropout: 0;
- *pos\_weight = none*

El reporte de las métricas obtenidas se encuentra en el Cuadro 1.

**Cuadro 1.** Tabla de reporte de métricas

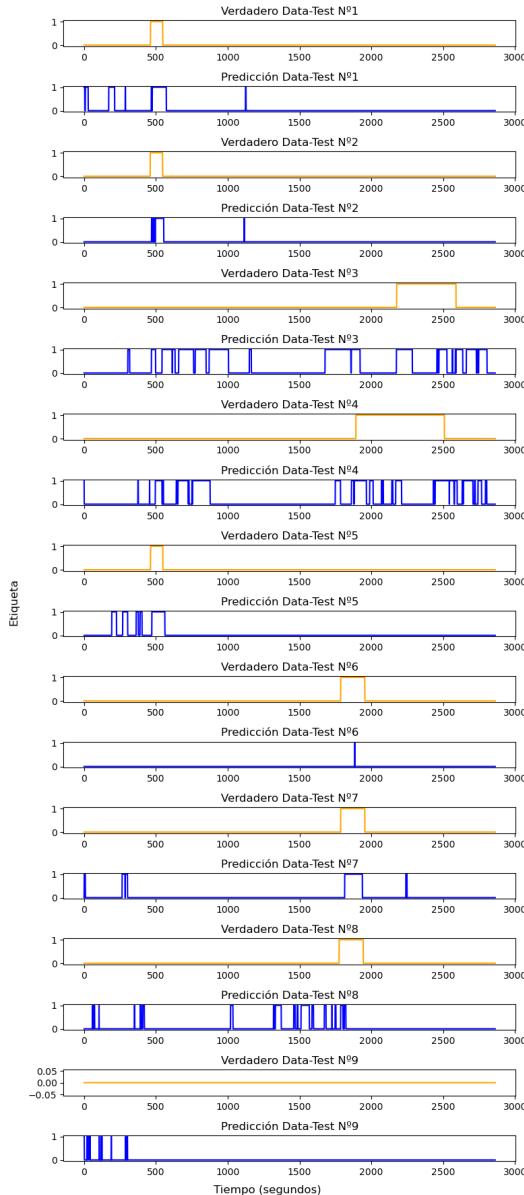
Etiqueta	Precisión	Recall	F1-Score	Support
Comportamiento normal (etiqueta = 0)	0.96	0.92	0.94	23977
Comportamiento antipredatorio (etiqueta = 1)	0.29	0.43	0.34	1790
<b>Accuracy</b>			0.89	25767
macro avg	0.62	0.67	0.64	25767
weighted avg	0.91	0.89	0.90	25767

La Figura 11 muestra la comparación del set de datos de prueba real y la predicción, utilizando el mejor modelo obtenido para la clasificación del comportamiento antipredatorio ovino.

En la Figura 12 se muestra la curva ROC y el área bajo la curva (AUC).

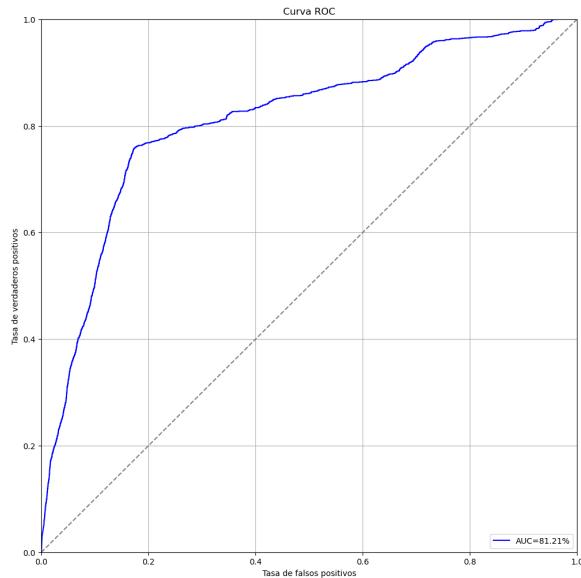
La matriz de confusión se encuentra en la Figura 14. En el eje horizontal se aprecia la etiqueta predicha, mientras que en el eje vertical, las etiquetas reales. A partir de esto, se obtienen la cantidad de Verdaderos Negativos (TN), Falsos Positivos (FP), Falsos Negativos (FN) y Verdadero Positivos (TP).

Los resultados obtenidos en el Cuadro 1, permiten hablar de la precisión, el Recall y el F1-Score del modelo. El valor de precisión obtenido, para identificar el comportamiento antipredatorio, fue de 29 %. Esto significa que un 29 % de la predicciones del comportamiento antipredatorio es correcto. Por otro lado, el Recall (exhaustividad) obtenido, fue de 43 %, lo que significa que el modelo es capaz de identificar un 43 % de los casos que son comportamiento antipredatorio. Este es un valor aceptable, ya que podría permitirse que el modelo no reconozca exhaustivamente cada instante en que los datos presentan un comportamiento antipredatorio, sino que, basta que reconozca un corto periodo para que así el sistema pueda enviar una alerta. En el caso del Recall para comportamiento normal, fue un valor del 92 %. Este valor indicó que el comportamiento normal se puede identificar correctamente, lo que implicaría que en muy pocas ocasiones se enviaran alertas falsas. Finalmente, el modelo retornó un F1-Score del 34 % en la detección del comportamiento antipredatorio, lo que quiere decir que en un 34 % de los casos, el modelo acertó. Esta métrica es útil para ver el rendimiento de clases que son desequilibradas, como es el caso del comportamiento antipredatorio.

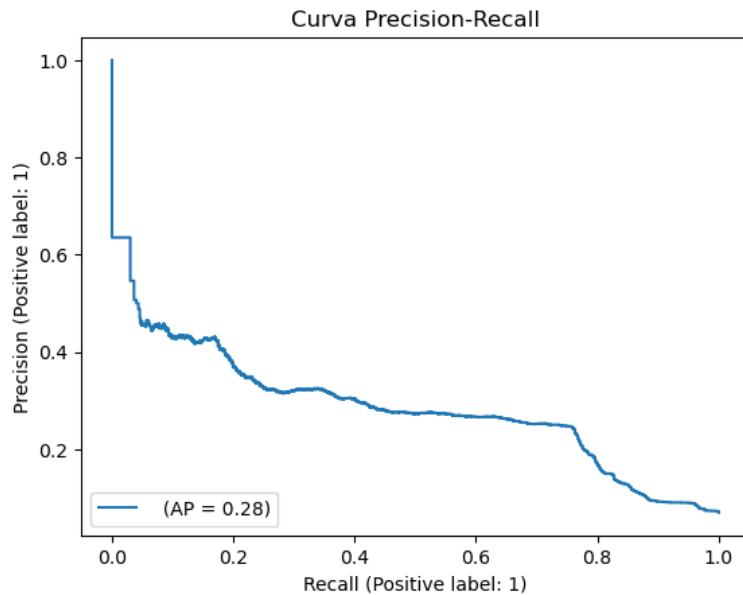


**Figura 11.** Comparación del conjuntos de datos de prueba de cada oveja ( $n=9$ ), entre la etiqueta real (naranjo) y la etiqueta predicha (azul) con el mejor modelo, donde, la etiqueta del comportamiento antipredatorio es 1 y el comportamiento normal es 0.

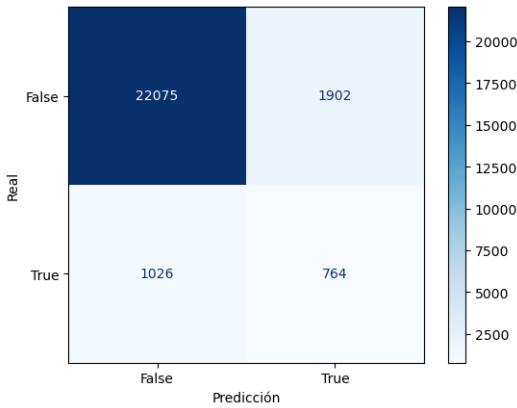
En la Figura 11, se puede comparar cada uno de los datos del set de prueba con la predicción realizada por el modelo. Entre los mejores está el Data-Test



**Figura 12.** Curva ROC para el modelo de clasificación del comportamiento antipredatorio ovino.



**Figura 13.** Curva Precisión-Recall para el modelo de clasificación del comportamiento antipredatorio ovino.



**Figura 14.** Matriz de confusión para el modelo de clasificación del comportamiento antipredatorio ovino.

N° 1, 2, 5 y 7, donde se observa que el modelo acertó en el instante que el comportamiento antipredatorio fue etiquetado y además, se observó que existieron algunos casos de falsos positivos que duran un corto periodo de tiempo, por lo que, en una aplicación real de este sistema, un falso positivo implicaría una vigilancia preventiva del rebaño. En el caso de los Data-Test N° 3, 4, 6 y 8, los resultados no fueron los esperados, en 3, 4 y 8 se observa una mayor cantidad de FP que TP, contrario a lo ocurrido en el Data-Test N° 6, donde solo hay un único instante en el que se predice una conducta antipredatoria. Por ultimo, en el Data-Test N° 9 solo se muestra etiqueta de un comportamiento normal ovino (etiqueta = 0), y en su predicción se observa que dentro los primeros segundos de tiempo ocurrieron unos cortos instantes dónde se predijeron falsos positivos. Estas diferencias de resultados entre los distintos Data-Test se pueden deber a la naturaleza de los datos, ya que en algunos ovinos es mucho más notorio el comportamiento antipredatorio. Los rebaños ovinos en una situación de depredación muestran su comportamiento jerárquico, donde las ovejas en la cúspide de la pirámide jerárquica confrontan y alertan al resto del rebaño, mientras que otras ovejas no son tan responsivas ante el ataque de un perro [11].

La curva ROC en la Figura 12, indicó un área bajo la curva (AUC) de 81.21 %. Esto se puede definir como un rendimiento satisfactorio, ya que el modelo evaluado con los datos de prueba demuestra ser mejor que un clasificador aleatorio, el cual posee un área bajo la curva AUC de 50 %.

La curva PR de la Figura 13 muestra los valores de precisión para los valores de recall correspondientes. La línea base de la curva PR esta dada por la tasa de positivos (P) y negativos (N),

$$y = P/(P + N)$$

Por lo que en este estudio se obtuvo un línea base dada por,

$$y = 7/(7 + 93)$$

$$y = 0,07$$

Dado el movimiento de la línea base, el área bajo la curva (AUC) de la curva PR también cambia en relación  $P : N$  [33]. El resultado AUC de la curva PR del modelo de clasificación del comportamiento antipredatorio ovino es de 0.28, siendo 4 veces mejor que la línea base.

En la matriz de confusión de la Figura 14, se observa una cantidad considerablemente mayor de Verdaderos Negativos (TN), que, sumado a los interpretados como Falsos Positivos (FP), muestran el desbalance de las clases del set de datos de prueba, correspondiendo un ~93% a la clase de comportamiento normal y un ~7% a la clase de comportamiento antipredatorio. Para la clases de comportamiento normal se aprecia como un ~92% de ellos fueron etiquetados correctamente y para la clase de comportamiento antipredatorio, un ~43% de los datos fueron etiquetados correctamente, lo cuál es un indicativo alentador considerando que se utilizaron dos series de tiempo recolectados de dos ovejas para realizar el entrenamiento.

Este trabajo si bien logra caracterizar el comportamiento de un rebaño ovino a pastoreo, e identificar de manera satisfactoria la conducta antipredatoria que muestra la oveja frente al ataque del perro, es posible con trabajos a futuro mejorar el rendimiento del modelo. Una primera instancia sería seleccionar las ovejas dominantes para que porten el dispositivo, ya que estas son las ovejas centinelas que más cambian su comportamiento frente a la presencia del perro. Por otro lado, se puede robustecer el sistema de medición incluyendo idealmente en todas las ovejas el módulo nRF24L01, para determinar con mayor exactitud el comportamiento de gregariedad que muestran los animales frente al ataque, e incluir este dato como una nueva característica del conjunto de datos del modelo, además, este modulo es de bajo costo, lo cual, permitiría utilizarlo en un mayor número de animales.

En otro ámbito, en trabajos a futuro se debe considerar también aspectos dentro de la metodología del entrenamiento del modelo que son mejorables, como implementar estrategias para balancear artificialmente el conjunto de datos, ya que por la naturaleza de estos, el comportamiento antipredatorio tiene una menor proporción que el comportamiento normal. También para la implementación del early stopping se debe utilizar un conjunto de datos distinto al conjunto de testeo, dado que la escasa cantidad de datos de ovejas en este estudio no permitió implementarlo de esa manera.

## 5. Conclusiones

A partir del estudio realizado podemos concluir que:

1. Se desarrolló un sistema de medición aplicable a las ovejas que entrega información relevante del cambio de comportamiento en pastoreo para alimentar con datos el modelo.

2. Es posible realizar una clasificación del comportamiento antipredatorio de la oveja frente al ataque de perros por medio de machine learning, utilizando un modelo basado en una Red Neuronal Recurrente.
3. Aún obteniendo un valor de F1-score del 34 %, se logra observar, en más de la mitad de los Data-Test de prueba, predicciones correctas en los momentos del ataque.
4. El modelo caracteriza el comportamiento antipredatorio de los animales a pastoreo, no obstante, entrega una variedad de falsos positivos, los cuales, añadiendo a futuro como requisito al sistema, que una cierta cantidad de datos clasificados como comportamiento antipredatorio deberían ocurrir ininterrumpidamente dentro de un corto periodo de tiempo para lanzar la alerta, eso disminuiría las notificaciones con falsas alertas.
5. Es factible realizar nuevas iteraciones para incrementar el rendimiento del modelo, como la realización de nuevas pruebas experimentales *in-situ* para obtener una mayor cantidad de datos para alimentar el modelo.

## Referencias

1. Bcewithlogitsloss - pytorch 1.13 documentation <https://pytorch.org/docs/stable/generated/torch.nn.bcewithlogitsloss.html>.
2. Pytorch <https://pytorch.org/>.
3. scikit-learn <https://scikit-learn.org>.
4. Reza Arablouei, Lachlan Currie, Brano Kusy, Aaron Ingham, Paul L. Greenwood, and Greg Bishop-Hurley. In-situ classification of cattle behavior using accelerometry data. *Computers and Electronics in Agriculture*, 183:106045, 2021.
5. C. Arcidiacono, S.M.C. Porto, M. Mancino, and G. Cascone. Development of a threshold-based classifier for real-time recognition of cow feeding and standing behavioural activities from accelerometer data. *Computers and Electronics in Agriculture*, 134:124–134, 2017.
6. Daniel Berckmans. General introduction to precision livestock farming. *Animal Frontiers*, 7(1):6–11, 2017.
7. Leo Breiman. Random forests. *Machine learning*, 45(1):5–32, 2001.
8. Gerardo Caja, Andreia Castro-Costa, and Christopher H Knight. Engineering to support wellbeing of dairy animals. *Journal of Dairy Research*, 83(2):136–147, 2016.
9. Gerardo Caja, Andreia Castro-Costa, Ahmed AK Salama, Joan Oliver, Mario Barratta, Carles Ferrer, and Christopher H Knight. Sensing solutions for improving the performance, health and wellbeing of small ruminants. *Journal of Dairy Research*, 87(S1):34–46, 2020.
10. Charles Carslake, Jorge A. Vázquez-Diosdado, and Jasmeet Kaler. Machine learning algorithms to classify and quantify multiple behaviours in dairy calves using a sensor: Moving beyond classification in precision livestock. *Sensors*, 21(1), 2021.
11. Roxana Cayul. Detección de posición jerárquica (liderazgo) en ovinos a través de análisis de videos y machine learning, 2020.
12. KyungHyun Cho, Bart van Merriënboer, Dzmitry Bahdanau, and Yoshua Bengio. On the properties of neural machine translation: Encoder-decoder approaches. *CoRR*, abs/1409.1259, 2014.

13. T. I. Chowdhury, M. M. Rahman, Sadre-Ala Parvez, A. K. M. M. Alam, Abul Basher, Abusayeed Alam, and Shahriar Rizwan. A multi-step approach for rssi-based distance estimation using smartphones. In *2015 International Conference on Networking Systems and Security (NSysS)*, pages 1–5, 2015.
14. Instituto Nacional de Estadísticas Chile INE. Encuesta de ganado ovino 2015.
15. Robert M Hanson Douglas Brown, Wolfgang Christian. Tracker: Video analisys and modeling tool.
16. Heitor Fonseca. Implementação e análise do nrf24l01+ como beacon bluetooth low energy, 2016.
17. Pengfei Gui, Liqiong Tang, and Subhas Mukhopadhyay. Mems based imu for tilting measurement: Comparison of complementary and kalman filter based data fusion. In *2015 IEEE 10th conference on Industrial Electronics and Applications (ICIEA)*, pages 2004–2009. IEEE, 2015.
18. Sara C. Gurule, Colin T. Tobin, Derek W. Bailey, and Jennifer A. Hernandez Gifford. Evaluation of the tri-axial accelerometer to identify and predict parturition-related activities of debouillet ewes in an intensive setting. *Applied Animal Behaviour Science*, 237:105–296, 2021.
19. Ilan Halachmi, Marcella Guarino, Jeffrey M. Bewley, and Matti Pastell. Smart animal agriculture: Application of real-time sensors to improve animal well-being and production. *Annual review of animal biosciences*, 7:403–425, 2019.
20. Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
21. Seyedehfaezeh Hosseini noorbin, Siamak Layeghy, Brano Kusy, Raja Jurdak, Greg J Bishop-Hurley, Paul L Greenwood, and Marius Portmann. Deep learning-based cattle behaviour classification using joint time-frequency data representation. *Computers and Electronics in Agriculture*, 187:106241, 2021.
22. jarzebski. <https://github.com/jarzebski/Arduino-KalmanFilter/blob/master/KalmanFilter.cpp>.
23. Kasirat Turfi Kasfi, Andrew Hellicar, and Ashfaqur Rahman. Convolutional neural network for time series cattle behaviour classification. In *Proceedings of the Workshop on Time Series Analytics and Applications*, pages 8–12, 2016.
24. Maninder Jeet Kaur and Piyush Maheshwari. Smart tourist for dubai city. In *2016 2nd International Conference on Next Generation Computing Technologies (NGCT)*, pages 30–34, 2016.
25. Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization, 2014. cite arxiv:1412.6980Comment: Published as a conference paper at the 3rd International Conference for Learning Representations, San Diego, 2015.
26. Angela Krueger, Jenifer Cruickshank, Erminio Trevisi, and Massimo Bionaz. Systems for evaluation of welfare on dairy farms. *Journal of Dairy Research*, 87(S1):13–19, 2020.
27. Ephraim Maltz. Individual dairy cow management: achievements, obstacles and prospects. *Journal of Dairy Research*, 87(2):145–157, 2020.
28. Carl Nord and Jacob Keeley. An introduction to the hpforest procedure and its options. In *Midwest SAS Users Group Conference Proceedings; Cincinnati, OH. Paper AA20*, 2016.
29. MEHMET OZGUVEN. *Digital Age in Agriculture*. ROUTLEDGE, 2023.
30. J. Ross Quinlan. Induction of decision trees. *Machine learning*, 1(1):81–106, 1986.
31. Ashfaqur Rahman, Daniel Smith, James Hills, Greg Bishop-Hurley, Dave Henry, and Richard Rawnsley. A comparison of autoencoder and statistical features for cattle behaviour classification. In *2016 international joint conference on neural networks (IJCNN)*, pages 2954–2960. IEEE, 2016.

32. William Moy Stratton Russell and Rex Leonard Burch. *The principles of humane experimental technique*. Methuen, 1959.
33. Takaya Saito and Marc Rehmsmeier. The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets. *PloS one*, 10(3):e0118432, 2015.
34. Sthephanie Schacht. Estudio preliminar del comportamiento antipredatorio en la oveja doméstica (*ovis aries*) para el desarrollo de un método de prevención de la depredación, 2013.
35. Christina Umstaetter, Anthony Waterhouse, and J.P. Holland. An automated sensor-based method of simple behavioural classification of sheep in extensive systems. *Computers and Electronics in Agriculture*, 64:19–26, 11 2008.
36. Liang Wang, Reza Arablouei, Flavio A.P. Alvarenga, and Greg J. Bishop-Hurley. Classifying animal behavior from accelerometry data via recurrent neural networks. *Computers and Electronics in Agriculture*, 206:107647, 2023.